

SKRIPSI

PENGEMBANGAN MODEL PERAMALAN PENJUALAN *FAST FOOD* DENGAN XGBOOST MENGGUNAKAN PYTHON



Disusun oleh:

Mim Hanifah Permana
NIM. 11200930000048

PROGRAM STUDI SISTEM INFORMASI
FAKULTAS SAINS DAN TEKNOLOGI
UNIVERSITAS ISLAM NEGERI SYARIF HIDAYATULLAH JAKARTA
2024 M/1446 H

SKRIPSI

PENGEMBANGAN MODEL PERAMALAN PENJUALAN *FAST FOOD* DENGAN XGBOOST MENGGUNAKAN PYTHON

Sebagai Salah Satu Syarat Untuk Memperoleh Gelar Sarjana Komputer

Fakultas Sains dan Teknologi

Universitas Islam Negeri Syarif Hidayatullah Jakarta



Disusun oleh:

Mim Hanifah Permana

NIM. 11200930000048

PROGRAM STUDI SISTEM INFORMASI

FAKULTAS SAINS DAN TEKNOLOGI

UNIVERSITAS ISLAM NEGERI SYARIF HIDAYATULLAH JAKARTA

2024 M/1446 H



LEMBAR PERNYATAAN

DENGAN INI SAYA MENYATAKAN BAHWA SKRIPSI INI BENAR-BENAR HASIL KARYA SENDIRI DAN BELUM PERNAH DIAJUKAN SEBAGAI SKRIPSI ATAU KARYA ILMIAH PADA PERGURUAN TINGGI ATAU LEMBAGA MANAPUN.

Jakarta, 18 Juli 2024



Mim Hanifah Permana
NIM. 11200930000048



ABSTRAK

Mim Hanifah Permana–11200930000048, Pengembangan Model Peramalan Penjualan *Fast Food* dengan XGBoost Menggunakan Python, di bawah bimbingan **Meinarini Catur Utami, M.T.** dan **Elvi Fetrina, M.IT.**

Dinamika pasar industri *fast food* menuntut perencanaan produksi yang efektif, terutama bagi bisnis *franchise* dengan lebih dari 300 outlet seperti D’besto. D’besto belum memiliki sistem peramalan penjualan yang akurat, menyebabkan sering terjadi *overstock* yang diperkirakan mencapai 30 produk per hari. D’besto juga kerap mengalami *understock* yang menimbulkan ulasan negatif. Kedua permasalahan ini dapat berdampak buruk bagi keberlangsungan bisnis perusahaan. Tujuan penelitian ini adalah untuk mengetahui perkiraan volume penjualan harian, angka *safety stock*, dan *reorder point*. Penelitian ini menggunakan data penjualan harian periode Januari 2023–Juni 2024 dan data hari libur nasional. Penelitian ini menggunakan *library* XGBoost untuk melakukan peramalan penjualan dan dievaluasi dengan *Root Mean Squared Error* (RMSE) dan *Mean Absolute Percentage Error* (MAPE). Peramalan penjualan pada penelitian ini menggunakan bantuan *tools* Google Colab untuk menjalankan Python dan *tools* Microsoft Excel untuk perhitungan *safety stock* serta *reorder point*. Hasil penelitian menunjukkan rata-rata prediksi penjualan harian di D’besto GDC sebesar 435 produk per harinya dengan RMSE 61,89 dan MAPE 10,2%, serta *safety stock* 98 dan *reorder point* 968. Di D’besto Tapos, rata-rata prediksi penjualan harian mencapai 360 produk per hari dengan RMSE 56,2 dan MAPE 14,1%, serta *safety stock* 120 dan *reorder point* 840. Penelitian ini berhasil memprediksi volume penjualan harian yang tergolong ke dalam kategori peramalan yang baik. Perhitungan *safety stock* dan *reorder point* yang dilakukan disertai rekomendasi pengendalian persediaan, dapat menjadi solusi efektif untuk mengurangi masalah *overstock* dan *understock* yang kerap terjadi.

Kata Kunci: Peramalan penjualan, python, *reorder point*, *safety stock*, XGBoost.

Bab 1–5 + xxvi Halaman + 95 Halaman + 36 Gambar + 13 Tabel + Lampiran
Pustaka Acuan (46, 2019–2024)



KATA PENGANTAR

Assalamualaikum Warahmatullahi Wabarakatuh

Puji dan syukur atas kehadiran Allah SWT yang telah memberikan rahmat serta hidayah-Nya sehingga penulis dapat menyelesaikan skripsi ini. Shalawat serta salam selalu tercurahkan kepada junjungan kita Rasulullah Muhammad SAW yang telah membawa kita keluar dari zaman kegelapan.

Pada skripsi ini, penulis menyadari bahwa masih banyak terdapat kekurangan. Namun demikian, skripsi ini dapat memenuhi salah satu syarat memperoleh gelar Sarjana Komputer strata satu (S1) Program Studi Sistem Informasi di Fakultas Sains dan Teknologi UIN Syarif Hidayatullah Jakarta. Skripsi yang berjudul **“Pengembangan Model Peramalan Penjualan *Fast Food* dengan XGBoost Menggunakan Python”** akhirnya dapat diselesaikan sesuai dengan harapan penulis. Selama penyusunan skripsi ini, penulis menghadapi banyak kesulitan dan tantangan.

Pada kesempatan ini penulis juga hendak mengucapkan terima kasih kepada pihak-pihak yang telah membantu memberikan dukungan, sehingga penulis dapat menyelesaikan skripsi ini. Ucapan terima kasih secara khusus penulis berikan kepada:

1. Bapak Husni Teja Sukmana, S.T., M.Sc, Ph.D. selaku Dekan Fakultas Sains dan Teknologi Universitas Islam Negeri Syarif Hidayatullah Jakarta.
2. Ibu Dr. Qurrotul Aini, M.T. selaku Ketua Program Studi Sistem Informasi Fakultas Sains dan Teknologi.
3. Bapak Ir. Eri Rustamaji, MBA selaku Sekretaris Program Studi Sistem Informasi Fakultas Sains dan Teknologi.
4. Ibu Meinarini Catur Utami, M.T. selaku Dosen Pembimbing I dan Ibu Elvi Fetrina M.IT. selaku Dosen Pembimbing II yang telah menyediakan waktunya untuk memberikan ilmu dan tentunya dukungan kepada penulis
5. Dosen-dosen Program Studi Sistem Informasi yang telah memberikan ilmu selama perkuliahan.

6. PT Evalinda Berkah Mandiri (EBM) yang telah memberikan izin kepada penulis untuk melakukan penelitian terkait peramalan penjualan produk.
7. Keluarga dan teman angkatan yang selalu memberikan motivasi, semangat serta arahan selama penyusunan laporan ini dimulai hingga selesai.
8. Semua pihak yang tidak dapat disebutkan satu per satu yang telah menemani peneliti dari awal perkuliahan hingga laporan skripsi ini terselesaikan.

Penulis menyadari bahwa dalam penyusunan skripsi ini masih jauh dari kata sempurna. Oleh karena itu, penulis tidak menutup diri atas segala bentuk saran dan kritik yang bersifat membangun ke depannya. Akhir kata, semoga skripsi ini dapat bermanfaat bagi pembaca dan penulis sendiri.

Wassalamualaikum Warahmatullahi Wabarakatuh.

Tangerang Selatan, 7 Juli 2024



Mim Hanifah Permana
NIM. 11200930000048

Universitas Islam Negeri
YARIF HIDAYATULLAH JAKARTA

DAFTAR ISI

SKRIPSI.....	i
LEMBAR PENGESAHAN SKRIPSI	iii
LEMBAR PENGESAHAN UJIAN	v
LEMBAR PERNYATAAN	vii
ABSTRAK	ix
KATA PENGANTAR.....	xi
DAFTAR ISI.....	xiii
DAFTAR GAMBAR.....	xvii
DAFTAR TABEL	xix
BAB 1 PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Identifikasi Masalah	14
1.3 Rumusan Masalah	15
1.4 Batasan Masalah	16
1.5 Tujuan Penelitian	16
1.6 Manfaat Penelitian	17
1.6.1 Bagi Peneliti.....	17
1.6.2 Bagi Universitas	17
1.6.3 Bagi Perusahaan.....	18
1.6.4 Bagi Ilmu Pengetahuan	18
1.7 Metodologi Penelitian	19
1.7.1 Metode Pengumpulan Data.....	19
1.7.2 Metode Peramalan Penjualan.....	20
1.7.3 Metode Perhitungan <i>Reorder Point</i>	21
1.8 Sistematika Penulisan	22
BAB 2 TINJAUAN PUSTAKA.....	25
2.1 Peramalan Penjualan	25
2.1.1 Pengertian Peramalan Penjualan.....	25
2.1.2 Metode Peramalan Penjualan.....	26

2.2	<i>Machine Learning</i>	29
2.2.1	XGBoost	29
2.3	Persentase Kesalahan	31
2.3.1	<i>Root Mean Squared Error (RMSE)</i>	31
2.3.2	<i>Mean Absolute Percentage Error (MAPE)</i>	31
2.4	<i>Tools</i>	32
2.4.1	Python	32
2.4.2	Google Colab	33
2.4.3	Microsoft Excel.....	33
2.5	Persediaan.....	34
2.5.1	<i>Safety Stock</i>	35
2.5.2	<i>Reorder Point (ROP)</i>	35
2.6	Literatur Sejenis	36
BAB 3 METODOLOGI PENELITIAN		45
3.1	Pendekatan Penelitian	45
3.2	Tahapan Penelitian	46
3.3	Deskripsi Tahapan Penelitian.....	46
3.3.1	Studi Pustaka.....	46
3.3.2	Studi Lapangan	47
3.3.3	<i>Data Selection (Seleksi Data)</i>	48
3.3.4	<i>Data Preprocessing (Pra-Pemrosesan Data)</i>	48
3.3.5	<i>Data Transformation (Transformasi Data)</i>	49
3.3.5	<i>Train-test Split (Pembagian Data Training dan Data Testing)</i>	50
3.3.6	<i>Data Mining (Pemilihan dan Ekstraksi)</i>	50
3.3.7	<i>Evaluation/Interpretation (Evaluasi/Interpretasi)</i>	51
3.3.8	Perhitungan <i>Safety Stock</i>	52
3.3.9	Perhitungan <i>Reorder Point</i>	52
3.4	Waktu Penelitian	52
BAB 4 HASIL DAN PEMBAHASAN		55
4.1	<i>Data Selection (Seleksi Data)</i>	55
4.2	<i>Data Preprocessing (Pra-Pemrosesan Data)</i>	57

4.2.1	<i>Handling Missing Values</i>	59
4.2.2	<i>Feature Engineering</i>	61
4.3	<i>Data Transformation</i> (Transformasi Data)	63
4.4	<i>Train-test Split</i> (Pembagian Data <i>Training</i> dan Data <i>Testing</i>)	63
4.5	<i>Data Mining</i> (Pemilihan dan Ekstraksi).....	64
4.5.1	Peramalan Penjualan D’besto GDC	65
4.5.2	Peramalan Penjualan D’besto Tapos	69
4.6	<i>Evaluation/Interpretation</i> (Evaluasi/Interpretasi)	73
4.7	Perhitungan <i>Safety Stock</i>	78
4.8	Perhitungan <i>Reorder Point</i>	79
4.9	Rekomendasi	80
4.9.1	Implementasi Sistem Peramalan Penjualan	81
4.9.2	Visualisasi <i>Dashboard</i> Peramalan Penjualan	81
4.9.3	Pengendalian Persediaan Bahan Baku	86
4.9.4	Strategi Promosi	86
4.9.5	Peningkatan Layanan dan Kualitas	87
BAB 5	PENUTUP	87
5.1	Kesimpulan	87
5.2	Saran.....	88
DAFTAR PUSTAKA		89
LAMPIRAN		xxi

Universitas Islam Negeri
YARIF HIDAYATULLAH JAKARTA



DAFTAR GAMBAR

Gambar 1.1 Nilai Pasar Layanan Makanan Berdasarkan Tipe Layanan	2
Gambar 1.2 Penjualan Mingguan Berdasarkan Jenis Produk pada Tahun 2022 D’besto GDC.....	8
Gambar 1.3 Komentar Negatif pada Ulasan Google D’BestO	11
Gambar 2.1 Metode Peramalan Penjualan.....	26
Gambar 2.2 Ilustrasi Algoritma XGBoost	30
Gambar 3.1 Tahapan Penelitian.....	46
Gambar 4.1 Data Penjualan dan Hari Libur Nasional.....	57
Gambar 4.2 Kode dan Hasil Deskripsi Data	58
Gambar 4.3 Kode dan Hasil Pengecekan <i>Missing Values</i>	59
Gambar 4.4 Distribusi Data Penjualan D’besto GDC & Tapos.....	60
Gambar 4.5 Kode dan Hasil Penanganan <i>Missing Values</i>	61
Gambar 4.6 Kode dan Hasil <i>Feature Engineering</i>	62
Gambar 4.7 Perubahan Kolom ‘Date’ menjadi <i>index</i>	63
Gambar 4.8 Pembagian Data Training dan <i>Data Testing</i>	64
Gambar 4.9 Instalasi <i>Library</i> XGBoost	64
Gambar 4.10 Kode dan Hasil <i>Data Mining</i> D’besto GDC	65
Gambar 4.11 Kode dan Hasil RMSE dan MAPE Peramalan Penjualan D’besto GDC	66
Gambar 4.12 Kode <i>Cross-validation</i> Peramalan Penjualan D’besto GDC.....	66
Gambar 4.13 Pembagian Data untuk Peramalan Penjualan.....	67
Gambar 4.14 Hasil Peramalan Penjualan D’besto GDC Periode Juli–Desember 2024.....	68
Gambar 4.15 Kode dan Hasil <i>Data Mining</i> D’besto Tapos	70
Gambar 4.16 Kode dan Hasil RMSE dan MAPE Peramalan Penjualan D’besto Tapos	70
Gambar 4.17 Hasil Peramalan Penjualan D’besto Tapos Periode Juli–Desember 2024.....	72
Gambar 4.18 Kode Pengecekan <i>Feature Importance</i>	74

Gambar 4.19 <i>Feature Importance</i> terhadap Data Penjualan D’besto GDC.....	74
Gambar 4.20 <i>Feature Importance</i> terhadap Data Penjualan D’besto Tapos	75
Gambar 4.21 Rata-rata Penjualan Harian Berdasarkan Hari	76
Gambar 4.22 Perbandingan Penjualan pada Hari Libur dan Bukan Libur di D’besto GDC.....	77
Gambar 4.23 Perbandingan Penjualan pada Hari Libur dan Bukan Libur di D’besto Tapos	78
Gambar 4.24 Tampilan <i>Dashboard</i>	82
Gambar 4.25 Tampilan Grafik Penjualan Satu Minggu Terakhir.....	83
Gambar 4.26 Tampilan Grafik Prediksi Penjualan Seminggu Kedepan.....	83
Gambar 4.27 Tampilan Prediksi dan Aktualisasi Penjualan Hari Ini	84
Gambar 4.28 Tampilan Prediksi Penjualan Berdasarkan Periode	85
Gambar 4.29 Tampilan Ringkasan Status Stok Bahan Baku.....	85
Gambar 4.30 Tampilan Notifikasi Pemesanan Ulang.....	86

DAFTAR TABEL

Tabel 1.1 Total Investasi Bisnis Lokal Fast Food.....	6
Tabel 1.2 Perkiraan Laba Bersih dan BEP Bisnis <i>Franchise Fried Chicken</i> Lokal	6
Tabel 1.3 Penjualan pada D’besto GDC dan Tapos (2022–2023).....	8
Tabel 3.1 Kriteria MAPE.....	51
Tabel 3.2 Waktu Penelitian	53
Tabel 4.1 Sampel Data Penjualan Harian <i>Fried Chicken</i> pada Outlet D’besto GDC dan Tapos.....	55
Tabel 4.2 Sampel Data Hari Libur Nasional	56
Tabel 4.3 Hasil <i>Cross-validation</i> Peramalan Penjualan D’besto GDC.....	66
Tabel 4.4 Hasil Peramalan Penjualan D’besto GDC	68
Tabel 4.5 Hasil <i>Cross-validation</i> Peramalan Penjualan D’besto Tapos	71
Tabel 4.6 Hasil Peramalan Penjualan D’besto GDC	72
Tabel 4.7 Rata-Rata dan Standar Deviasi Prediksi Penjualan Harian.....	78
Tabel 4.8 Hasil Perhitungan <i>Safety Stock</i> dan <i>Reorder Point</i>	80


BAB 1

PENDAHULUAN

1.1 Latar Belakang

Pola hidup masyarakat yang mengutamakan efisiensi dalam perolehan makanan sehari-hari, berdampak pada pergeseran pola konsumsi pangan ke arah *fast food* atau makanan cepat saji. Penerimaan masyarakat terhadap *fast food* sebagai pilihan konsumsi makanan didukung dengan banyaknya jumlah restoran *fast food* yang tersebar luas. Budihardjo Iduansjah, Ketua Himpunan Penyewa Pusat Perbelanjaan Indonesia, memproyeksikan bahwa bisnis restoran *fast food* memiliki potensi pertumbuhan antara 15%–18%, yaitu lebih tinggi dari perkiraan pertumbuhan bisnis waralaba secara keseluruhan pada angka 10% (Richard, 2019).

Berdasarkan data dari Straits Research (2024), ukuran pasar *fast food* global pada tahun 2023 berada di angka 772.04 miliar USD. Pada tahun 2019–2020, pasar *fast food* mengalami penurunan signifikan akibat pandemi yang menuntut adanya pembatasan sosial (Allied, 2020; KBV, 2021). Gambar 1.1 menunjukkan bahwa pada 2020–2023, pasar *fast food* menunjukkan peningkatan yang baik setelah masa penurunan sebelumnya (Coherent, 2023; GVR, 2022). Pertumbuhan ukuran pasar *fast food* yang dinamis selama lima tahun tersebut diiringi dengan proyeksi pertumbuhan yang optimis pada periode 2024–2032. Proyeksi tingkat pertumbuhan tahunan gabungan (CAGR) pada periode prediksi tersebut adalah sebesar 4,89%. Hal ini mengindikasikan pasar industri *fast food* memiliki pertumbuhan yang kuat dan dinamis.



Gambar 1.1 Ukuran Pasar Industri *Fast Food* Global

Industri *fast food* di Indonesia menunjukkan popularitas yang kuat, tercermin dari tingginya minat masyarakat Indonesia dalam mengonsumsi *fast food*. Survei yang dilakukan oleh Nilsen dalam Wahyuni & Nugroho. (2022), menyatakan bahwa mayoritas penduduk Indonesia, yaitu sebesar 69%, mengonsumsi *fast food*. Berdasarkan data dari Kementerian Pertanian, konsumsi *fast food* menyumbang sebanyak 28% dari total kalori yang dikonsumsi oleh masyarakat perkotaan di Indonesia (Kristanti *et al.*, 2024). Kemudahan akses, harga yang lebih terjangkau, serta konsistensi kualitas menjadi faktor utama tingginya popularitas industri *fast food* (Wahab *et al.*, 2023). Menurut hasil survei Kurious dari Katadata *Insight Center* (KIC), mayoritas masyarakat Indonesia mengonsumsi makanan *fast food* lebih dari satu kali dalam sepekan (Annur, 2023). Ini menunjukkan bahwa bisnis *fast food* di Indonesia memiliki posisi yang kuat dalam pasar industri *fast food* global yang dinamis.

Dinamika pasar industri *fast food* menuntut industri untuk melakukan perencanaan produksi secara efektif, terutama bagi bisnis *fast food* yang memiliki banyak *franchise*. Kebijakan manajemen perusahaan mengatur pentingnya peranan perencanaan produksi terutama ketika menghadapi perubahan lingkungan yang dinamis. Perencanaan produksi merupakan hal yang krusial dan memerlukan proses sistematis dengan pendekatan yang mengandalkan rasionalitas dibandingkan dengan sekedar intuisi saja (Muktamar *et al.*, 2023).

Perencanaan produksi yang cermat dibutuhkan untuk mengantisipasi perubahan tren konsumen dan menjaga ketersediaan produk yang konsisten di setiap *franchise* dengan tujuan mampu memenuhi harapan pelanggan, mempertahankan reputasi merek dan kinerja keuangan bisnis secara keseluruhan. Perencanaan produksi yang baik didukung dengan peramalan penjualan yang akurat. Peramalan penjualan atau *sales forecasting* memiliki manfaat besar dalam proses pengambilan keputusan terkait perencanaan dan pengembangan produk. Selain itu, peramalan penjualan memungkinkan perusahaan untuk menyusun anggaran dan mengalokasikan sumber daya dengan tepat, sehingga dapat meminimalkan pengeluaran dan maksimalkan profit (Koufi, Belangour, & Sidiq 2022). Penelitian yang dilakukan oleh Putra (2019) menunjukkan bahwa peramalan penjualan memiliki dampak positif dan signifikan terhadap volume penjualan suatu perusahaan. Oleh karena itu, penting bagi perusahaan seperti restoran *fast food* untuk melakukan peramalan penjualan dengan tingkat akurasi yang tinggi. Kesalahan dalam peramalan penjualan dapat menimbulkan dua masalah utama, yaitu *understock* dan *overstock* (Fitriyah, Dahda, & Ismiyah, 2022).

Kekurangan persediaan bahan pangan untuk menghasilkan produk, atau yang dikenal sebagai kondisi *understock* dapat mengganggu kelancaran operasional perusahaan. Jika produk yang diminta oleh pelanggan tidak tersedia, maka dapat menimbulkan ketidakpuasan pelanggan, berkurangnya loyalitas pelanggan, hingga hilangnya potensi penjualan. Berdasarkan studi yang dilakukan oleh *National Retail Federation* (NRF), kondisi *understock* mengakibatkan perusahaan kehilangan potensi penjualan sebesar 4–8% dari keuntungan yang mereka dapatkan (Presswire, 2024). Untuk mengatasi *understock*, salah satu pendekatan yang efektif adalah dengan melakukan perhitungan *reorder point* secara cermat. *Reorder point* adalah titik persediaan di mana pemesanan ulang harus dilakukan untuk menghindari kekurangan stok. Dengan memperhitungkan faktor-faktor seperti permintaan, *lead time* dan angka *safety stock*, perusahaan dapat menentukan kapan saat yang tepat untuk memesan ulang bahan baku sehingga dapat menjaga ketersediaan stok yang optimal tanpa kelebihan atau kekurangan yang signifikan. Dengan demikian, penggunaan perhitungan *reorder point* secara tepat dapat membantu industri *fast food* mengurangi risiko *understock* maupun *overstock* (Heaviside, Mulyawan, & Sutrisno, 2020).

Overstock merupakan kondisi di mana perusahaan memiliki persediaan barang yang melebihi permintaan pasar. *Overstock* pada industri makanan dapat meningkatkan angka *food waste* dan *food loss* karena makanan yang tidak terjual akan membusuk dan harus dibuang. Menurut *Food and Agriculture Organization* (FAO), *food waste* mengacu kepada penurunan kualitas atau kuantitas di tingkat ritel, jasa penyedia makanan, dan konsumen. Sementara *food loss* merupakan

makanan terbuang sebelum mencapai konsumen. Badan Perencanaan Pembangunan Nasional (Bappenas) mengestimasi, nilai kehilangan ekonomi pada tahap *food loss* sekitar 106–205 triliun rupiah per tahun. Sementara nilai kehilangan ekonomi pada tahap *food waste* berkisar antara 107–346 triliun rupiah per tahun (Asia, 2024). Dalam industri *fast food*, persediaan bahan pangan yang berlebih memerlukan ruang penyimpanan dan biaya pemeliharaan tambahan yang dapat mengurangi profitabilitas perusahaan. Profitabilitas yang kuat dan konsisten dapat meningkatkan stabilitas perusahaan dan mendukung perkembangan bisnis jangka panjang (Perdana, 2019).

Salah satu bisnis lokal pada industri *fast food* yang perkembangannya cukup baik adalah D’besto. D’besto merupakan usaha *fast food* yang dimiliki oleh PT Evalinda Berkah Mandiri (EBM). D’besto fokus dalam menyediakan *fried chicken* sebagai menu utama dalam konsep mini resto yang sederhana. D’besto mengusung konsep berbeda dibanding pesaing dari luar negeri yang umumnya menasar segmen restoran. D’besto telah melebarkan sayap di beberapa daerah seperti Jabodetabek, Bandung, Banjarmasin, Padang, dan Pekanbaru. Konsep mini resto ini juga berbeda dari bisnis lokal *fried chicken* lainnya yang umumnya menyediakan *franchise* dalam bentuk *booth* atau gerobakan. Perbedaan D’besto dengan bisnis lokal lainnya juga terletak pada pilihan menu yang ditawarkan. Selain *fried chicken*, D’besto juga menyediakan pilihan produk lainnya seperti burger, kentang, *spaghetti*, dan beberapa menu lainnya.

Tabel 1.1 menunjukkan bahwa D’besto memiliki total investasi yang cukup besar dibandingkan dengan bisnis *fast food* lokal lainnya. Dengan total investasi di

angka lebih dari Rp60 miliar, D'besto mampu memiliki lebih dari 300 outlet dengan konsep mini resto yang menawarkan kenyamanan bagi pelanggan yang ingin makan disana.

Tabel 1.1 Total Investasi Bisnis Lokal *Fast Food*

No.	Nama <i>Brand</i>	Jenis <i>Franchise</i>	Harga <i>Franchise</i> (Rp)	Jumlah Outlet	Total Investasi (Rp)
1	D'kriuk	<i>Booth</i>	17 juta	>4000	>68 miliar
2	D'besto	Mini Resto	200 juta	>300	>60 miliar
3	Sabana	<i>Booth</i>	23 juta	>2500	>57,5 miliar
4	Crispyku	<i>Booth</i>	30 juta	>900	>27 miliar
5	C'bezt	Mini Resto	100 juta	>200	>20 miliar
6	Orchi	<i>Booth</i>	13,5 juta	>700	>9,5 miliar

D'besto memiliki angka perkiraan laba bersih yang cukup baik sehingga *franchisee* diperkirakan dapat balik modal dalam kurun waktu 6 bulan (Tabel 1.2). Perkiraan *Break Event Point* (BEP) milik D'besto termasuk cepat dibandingkan dengan *brand* lain dengan jenis *franchise* yang sama, yaitu mini resto. Data tersebut menunjukkan bahwa perkiraan pertumbuhan bisnis D'besto cukup baik dibandingkan dengan bisnis *fast food* lokal lainnya.

Tabel 1.2 Perkiraan Laba Bersih dan BEP Bisnis *Franchise Fried Chicken* Lokal

No.	Nama <i>Brand</i>	Perkiraan Laba Bersih (Rp)	Perkiraan <i>Break Event Point</i>
1	D'besto	37,5 juta	6 bulan
2	Crispyku	8,4 juta	3,5 bulan
3	C'bezt	8,4 juta	12 bulan
4	D'kriuk	4,2 juta	6 bulan
5	Sabana	7,6 juta	3 bulan

6	Orchi	7,5 juta	2 bulan
---	-------	----------	---------


Salah satu cara D'besto dalam menjaga keberlangsungan bisnisnya adalah dengan menerapkan sistem informasi terpusat dan terintegrasi di semua outlet. Manfaat dari sistem informasi ini satunya adalah pemantauan kinerja bisnis secara *real-time* yang memungkinkan manajemen untuk mengetahui kondisi setiap outlet dan mengambil tindakan cepat jika diperlukan. Sistem ini juga memastikan konsistensi dan keseragaman operasional yang penting untuk mempertahankan merek dan reputasi D'besto. Selain itu, data penjualan yang terkumpul dalam satu sistem dapat mempermudah pelaporan, analisis, identifikasi masalah, dan solusi, serta menjadi sumber informasi berharga untuk pengambilan keputusan strategis. Dengan demikian, sistem informasi ini tidak hanya meningkatkan efisiensi operasional tetapi juga memberikan keunggulan kompetitif bagi perusahaan.

Keunggulan kompetitif D'besto didukung oleh penjualan yang baik di setiap outletnya. Tingginya angka penjualan yang dimiliki D'besto dapat tercerminkan dari penjualan pada outlet D'besto GDC dan D'besto Tapos. Kedua outlet ini berlokasi di Depok, Jawa Barat. Tercatat bahwa volume penjualan pada kedua outlet ini mengalami peningkatan yang signifikan di tahun 2023 jika dibandingkan dengan tahun sebelumnya (Tabel 1.3). Menurut Stockpedia (2024), pertumbuhan penjualan yang baik bagi suatu perusahaan besar adalah sebesar 5%–10%. D'besto mampu mencapai pertumbuhan penjualan di angka 37% untuk D'besto GDC dan 17% untuk D'besto Tapos.

Tabel 1.3 Penjualan pada D'besto GDC dan Tapos (2022–2023)

No.	Nama Outlet	Tahun	Total Penjualan	Pertumbuhan
1	D'besto GDC	2022	Rp2.118.647.846	
		2023	Rp2.904.583.540	37%
2	D'besto Tapos	2022	Rp1.170.999.674	
		2023	Rp1.374.225.067	17%

Tingginya angka penjualan yang dimiliki perusahaan ini menunjukkan tingginya minat pasar terhadap produk D'besto terutama produk unggulannya yaitu *fried chicken*. Gambar 1.2 menunjukkan adanya perbedaan mencolok terhadap penjualan *fried chicken* dibandingkan dengan produk lainnya. Oleh karena itu, D'besto harus siap menjaga kualitas dan ketersediaan *fried chicken* untuk memenuhi kebutuhan pelanggan.



Gambar 1.2 Penjualan Mingguan Berdasarkan Jenis Produk pada Tahun 2022 D'besto GDC

Dalam upaya memenuhi tingginya permintaan terhadap produk *fried chicken*, D'besto menjamin proses pengiriman stok ayam *frozen* dari gudang ke masing-masing outlet dapat diselesaikan dalam waktu kurang dari 24 jam. Frekuensi pengiriman dan jumlah stok ayam *frozen* yang dikirimkan bergantung pada permintaan dari masing-masing outlet. Setiap outlet melakukan prediksi secara manual untuk menentukan jumlah ayam *frozen* yang akan dipasok. Ayam *frozen* yang telah diterima di masing-masing outlet kemudian dipindahkan ke dalam *freezer* agar terjaga kualitasnya. Sebelum diolah dengan cara digoreng, ayam *frozen* ini melewati tahap *thawing* yaitu proses dimana ayam *frozen* dikeluarkan dari *freezer* agar suhu dari ayam tersebut meningkat dan siap untuk digoreng.

D'besto menerapkan standar operasional perusahaan yang berfokus pada pelayanan dan kualitas produk. Perusahaan ini menerapkan sistem *First In First Out* (FIFO) untuk memastikan kesegaran produk yang diterima oleh konsumen. Standar operasional perusahaan menetapkan bahwa ayam *frozen* yang sudah memasuki tahap *thawing* tidak boleh dikembalikan ke dalam *freezer* dan harus digoreng pada hari yang sama. Apabila ayam yang sudah di-*thawing* tidak laku terjual pada hari tersebut, maka harus ditarik dari persediaan. Ayam yang sudah digoreng juga memiliki batas waktu untuk dapat dikatakan layak jual. *Fried chicken* yang belum terjual dalam waktu 2 jam setelah digoreng, perlu ditarik dari persediaan. Hal ini bertujuan untuk memastikan bahwa produk yang disajikan kepada konsumen selalu segar dan berkualitas.

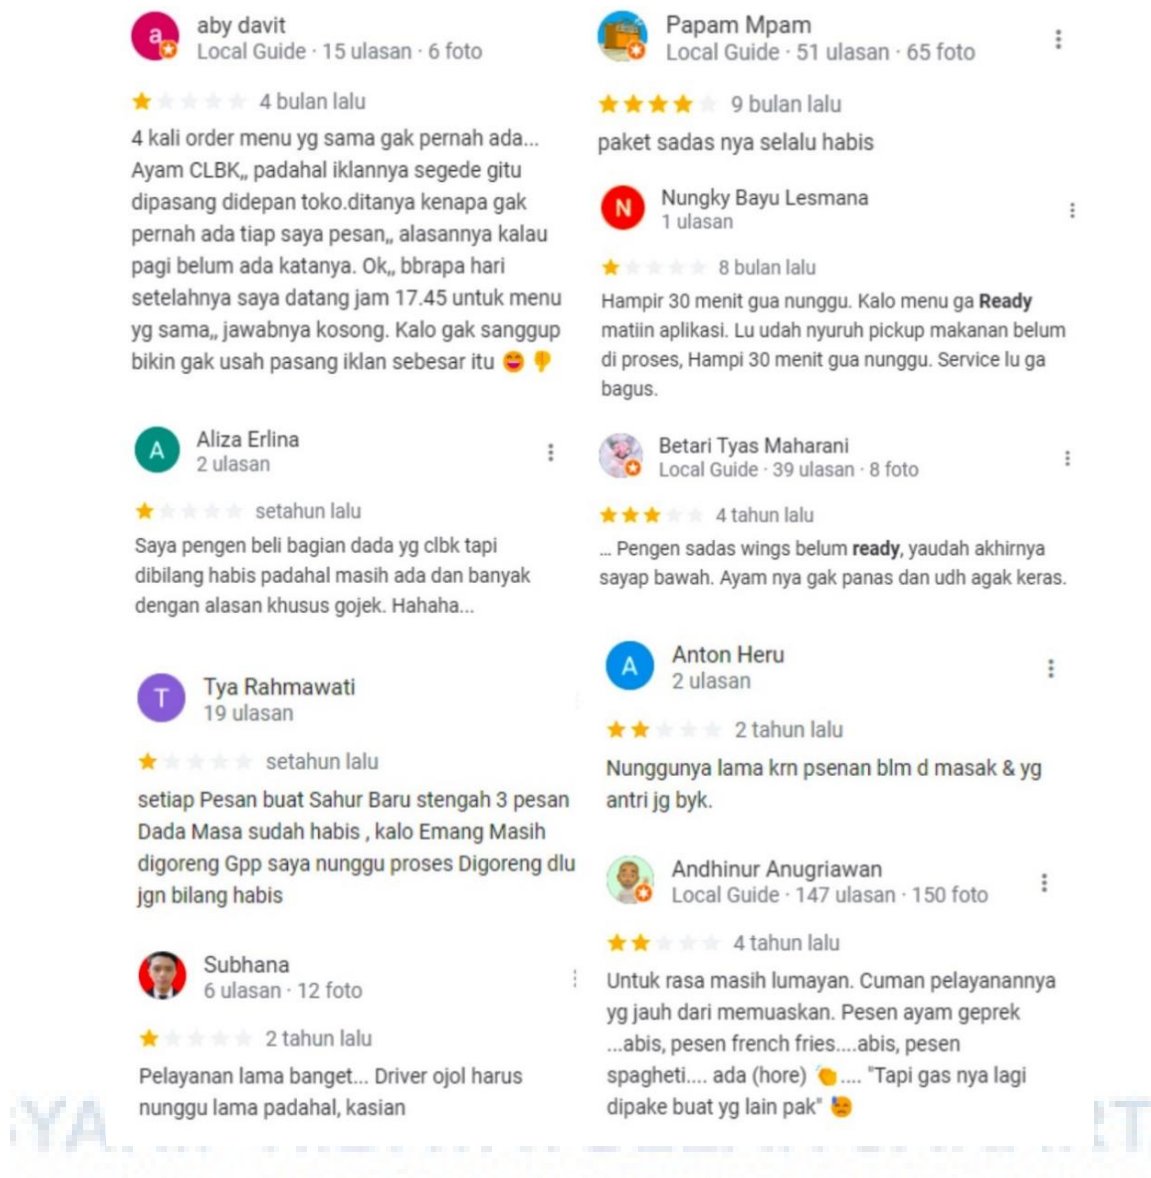
Berdasarkan hasil wawancara dengan Pak Rival selaku Kepala Restoran D'besto GDC, permasalahan mengenai *overstock* cukup sering terjadi dikarenakan

prediksi penjualan yang mereka terapkan masih dilakukan secara manual tanpa bantuan sistem atau *tools* tertentu. Diperkirakan setiap harinya, D'besto memiliki stok berlebih sebanyak 30 produk yang terpaksa ditarik dari penjualan. Situasi *overstock* ini menyebabkan peningkatan angka *food loss* dan *food waste*, yang berdampak negatif bagi keuntungan perusahaan. Pak Rival juga menambahkan bahwa, untuk mengurangi *overstock*, beberapa kali karyawan pada outlet ini memilih untuk membeli ayam yang ditarik dari persediaan agar tidak berdampak buruk pada penjualan perusahaan.

Selain *overstock*, D'besto beberapa kali mengalami kondisi *understock*. Terjadinya *understock* dapat terlihat dari ulasan Google D'besto. Terdapat beberapa ulasan buruk mengenai kurangnya persediaan produk yang mereka miliki. Kekurangan stok atau kondisi *understock* ini terjadi karena adanya kesenjangan perkiraan penjualan dengan realisasi penjualan.

Komentar-komentar pada Gambar 1.3 menunjukkan keluhan pelanggan mengenai produk yang belum siap dijual atau masih diproses sehingga pelanggan perlu menunggu beberapa waktu. Selain itu, terdapat pula komentar mengenai ketidaktersediaan produk yang diinginkan. Kondisi *understock* pada D'besto ini menimbulkan ketidakpuasan bagi pelanggan. Dalam sebuah industri, ulasan negatif di Google disertai penilaian dengan *rating* yang buruk dapat mempengaruhi volume penjualan. Ulasan buruk dapat mempengaruhi reputasi merek dan membuat pelanggan ragu untuk membeli produk suatu perusahaan. Oleh karena itu, kemampuan untuk mengantisipasi dan memenuhi permintaan pelanggan yang fluktuatif menjadi faktor penting untuk keberlangsungan bisnis perusahaan

(Pavlyshenko, 2019).



Gambar 1.3 Komentar Negatif pada Ulasan Google D'besto

Kondisi *overstock* maupun *understock* yang dialami D'besto disebabkan oleh kesalahan peramalan penjualan yang saat ini masih dilakukan secara manual. Sebagai perusahaan yang bergerak di bidang industri *fast food* dengan jumlah *franchise* lebih dari 300 outlet, D'besto membutuhkan sistem peramalan penjualan

yang akurat sehingga dapat meningkatkan keuntungan kumulatif dari seluruh outlet. Dengan peramalan penjualan yang baik, suatu perusahaan dapat melakukan optimalisasi pemasaran, promosi, hingga ekspansi jaringan kemitraan (Wiranda & Sadikin, 2019). D’besto dapat mewujudkan sistem peramalan penjualan dengan cara membangun model *machine learning* yang mampu memprediksi penjualan harian di masa depan. Menurut Huo (2021), model *machine learning* terbukti dapat digunakan dengan baik di berbagai skenario peramalan penjualan. Oleh karena itu, perbedaan data penjualan di masing-masing outlet D’besto tidak menjadi masalah karena model *machine learning* dapat menyesuaikan data yang digunakan untuk menghasilkan peramalan penjualan yang akurat di setiap outletnya. Untuk membangun model ini, D’besto perlu melatih data penjualan harian dari salah satu outletnya. Namun, penelitian ini menggunakan data penjualan harian dari dua outlet, yaitu D’besto GDC dan D’besto Tapos. Hal ini bertujuan untuk memastikan bahwa model yang dikembangkan dapat diimplementasikan secara efektif di seluruh jaringan outlet D’besto.

Salah satu metode yang umum digunakan untuk melakukan pengembangan model peramalan penjualan adalah XGBoost. Algoritma ini juga menunjukkan performa yang cukup baik pada beberapa penelitian terdahulu. Penelitian yang berjudul “*Developing and Preliminary Testing of a Machine Learning-Based Platform for Sales Forecasting Using a Gradient Boosting*” yang dievaluasi dengan *Root Mean Squared Error* (RMSE) dan *Mean Absolute Percentage Error* (MAPE) dan dua metrik evaluasi lainnya, menunjukkan bahwa algoritma XGBoost menghasilkan performa yang lebih baik dibandingkan algoritma Gradient Boosting

(Panarese *et al.*, 2022). XGBoost merupakan algoritma yang dapat mempertimbangkan faktor-faktor yang mempengaruhi penjualan dan tidak terikat pada faktor yang berhubungan dengan *timeseries* saja. Penelitian yang dilakukan oleh Raizada & Saini (2021) menunjukkan bahwa hari libur nasional dan beberapa faktor lainnya memiliki peran penting dalam melakukan peramalan penjualan di masa depan. Penelitian lain yang dilakukan oleh Haq, Alhakim, & Zuhdan (2023) terhadap penjualan roti di Yogyakarta menunjukkan bahwa hari libur nasional memiliki pengaruh terhadap peningkatan penjualan harian.

Salah satu penelitian yang melakukan peramalan penjualan dengan algoritma XGBoost memiliki judul “Analisis Prediktif untuk Keputusan Bisnis: Peramalan Penjualan”. Penelitian ini menyajikan penerapan analisis prediktif untuk menemukan wawasan yang berguna dalam pengambilan keputusan bisnis khususnya tentang peramalan penjualan produk kopi. Hasil pengujian menunjukkan bahwa algoritma XGBoost memiliki skor Mean Absolute Error sebesar 1,3%, masih lebih baik dibandingkan Linear Regression, Random Forest dan ARIMA dengan tingkat kesalahan sebesar 1,81%, 1,97%, 2,21% pada masing-masing algoritma. Penelitian ini menunjukkan bahwa kinerja dari algoritma XGBoost terbukti lebih baik dibandingkan dengan beberapa algoritma lainnya (Husein, Lubis, & Harahap, 2019).

Penelitian lain yang berjudul “*Machine Learning Model for Sales Forecasting by Using XGBoost*” yang dilakukan untuk memprediksi penjualan produk di toko ritel menunjukkan hasil bahwa model XGBoost tidak hanya mempercepat waktu eksekusi tetapi juga meningkatkan akurasi prediksi

dibandingkan metode *machine learning* lainnya. Hal ini dibuktikan dengan skor *Root Mean Squared Scaled Error* (RMSSE) sebesar 0.655, yang 16.3% lebih baik dibandingkan metode Regresi Linier dan 15.4% lebih baik dibandingkan metode Ridge Regression (Dairu & Shilong, 2021). Model *machine learning* dengan algoritma XGBoost ini akan dikembangkan menggunakan Python. Penggunaan Python dilakukan karena fungsinya dalam melakukan analisis, visualisasi, *pre-processing*, hingga pemodelan *machine learning*. Dibandingkan dengan *software* pengolah data yang terlihat lebih mudah, Python memiliki keunggulan khusus yaitu lebih fleksibel untuk proses *deployment* atau implementasi model ke sistem sesungguhnya (Hasan, 2024).

Berdasarkan uraian yang telah dipaparkan, penelitian terkait peramalan penjualan berdasarkan data historis penjualan dengan judul **“Pengembangan Model Peramalan Penjualan *Fast Food* dengan XGBoost Menggunakan Python”** dilakukan oleh penulis untuk menyelesaikan skripsi Program Studi Sistem Informasi di Fakultas Sains dan Teknologi Universitas Islam Negeri Syarif Hidayatullah Jakarta. Penelitian ini bertujuan untuk mengetahui performa XGBoost dalam melakukan peramalan penjualan serta perhitungan *safety stock* dan *reorder point* untuk produk *fried chicken* pada D'Besto dengan menggunakan data penjualan harian dari dua outlet yaitu D'besto GDC dan D'besto Tapos.

1.2 Identifikasi Masalah

Adapun identifikasi permasalahan pada penelitian ini adalah:

- a. Sering terjadi kondisi *overstock* yang mengakibatkan kerugian bagi perusahaan. Dengan tuntuan standar operasional perusahaan yang selalu menjamin kesegaran produk, sejumlah produk ataupun stok bahan baku yang tidak berhasil terjual dalam kurun waktu tertentu terpaksa ditarik dari penjualan. Diperkirakan setiap harinya, D'besto memiliki stok berlebih sebanyak 30 produk.
- b. Beberapa kali terjadi kondisi *understock* dimana permintaan pelanggan melebihi produk yang tersedia. Kondisi ini terjadi karena adanya kesenjangan perkiraan penjualan dengan realisasi penjualan. Kekecewaan pelanggan terhadap kondisi *understock* ini mengakibatkan munculnya ulasan negatif dan *rating* Google yang buruk.

1.3 Rumusan Masalah

Berdasarkan latar belakang permasalahan yang telah dipaparkan, maka dapat dirumuskan masalah dalam penelitian ini adalah sebagai berikut:

- a. Berapa hasil peramalan penjualan harian menggunakan XGBoost untuk produk *fried chicken* periode Juli–Desember 2024 pada outlet D'besto GDC dan D'besto Tapos?
- b. Berapa hasil perhitungan *safety stock* dan *reorder point* untuk produk *fried chicken* pada outlet D'besto GDC dan D'besto Tapos?

1.4 Batasan Masalah

Berdasarkan masalah yang telah dirumuskan pada bagian sebelumnya, maka ruang lingkup penelitian dibatasi pada:

- a. Penelitian ini dilakukan pada D'besto dengan mengambil sampel data penjualan harian pada D'besto GDC dan D'besto Tapos.
- b. Data yang dikumpulkan adalah data transaksi penjualan harian *fried chicken* periode Januari 2023–Juni 2024.
- c. Data yang digunakan untuk mendukung analisis peramalan penjualan ini adalah data hari libur nasional periode Januari 2023–Desember 2024.
- d. Metode yang digunakan pada peramalan penjualan ini adalah XGBoost.
- e. *Tools* yang digunakan adalah Google Colab (untuk menjalankan Python) dan Microsoft Excel.
- f. Performa algoritma XGBoost dievaluasi menggunakan perhitungan *Root Mean Squared Error* (RMSE) dan *Mean Absolute Percentage Error* (MAPE).
- g. Hasil peramalan penjualan adalah volume penjualan harian selama 6 bulan yaitu Juli–Desember 2024.

1.5 Tujuan Penelitian

Berdasarkan batasan masalah yang telah penulis rumuskan, maka dapat disimpulkan tujuan dari penelitian ini, adalah:

- a. Melakukan peramalan penjualan harian menggunakan XGBoost untuk produk *fried chicken* periode Juli–Desember 2024 pada outlet D'besto GDC

dan D'besto Tapos.

- b. Melakukan perhitungan *safety stock* dan *reorder point* untuk produk *fried chicken* pada outlet D'besto GDC dan D'besto Tapos.

1.6 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan manfaat kepada beberapa pihak, yaitu:

1.6.1 Bagi Peneliti

Manfaat penelitian yang didapat peneliti adalah sebagai berikut:

- a. Memperluas pengetahuan dan keterampilan dalam memanfaatkan *machine learning* dalam melakukan peramalan penjualan.
- b. Peneliti dapat menerapkan ilmu yang sudah diperoleh selama masa perkuliahan, menambah wawasan, ilmu pengetahuan, dan pengalaman yang diperoleh selama proses penelitian ini.

1.6.2 Bagi Universitas

Manfaat penelitian yang didapat universitas adalah sebagai berikut:

- a. Penelitian ini dapat menjadi bahan evaluasi dan inspirasi dalam melakukan penelitian selanjutnya untuk universitas.
- b. Penelitian ini memperkaya ilmu pengetahuan di universitas dengan menambah kajian terkait penerapan *machine learning* dalam bidang peramalan penjualan dan manajemen persediaan, khususnya di industri makanan cepat saji.

1.6.3 Bagi Perusahaan

Manfaat penelitian yang didapat perusahaan adalah sebagai berikut:

- a. Penelitian ini memberikan model prediksi penjualan yang lebih akurat dengan menggunakan XGBoost, sehingga perusahaan dapat melakukan pengendalian persediaan stok bahan baku yang lebih efektif, mengurangi risiko *overstock* dan *understock*.
- b. Data prediktif dari penelitian ini membantu manajemen perusahaan dalam membuat keputusan strategis yang lebih baik terkait produksi, distribusi, dan penawaran produk, berdasarkan tren penjualan yang terukur secara ilmiah.

1.6.4 Bagi Ilmu Pengetahuan

Manfaat penelitian bagi ilmu pengetahuan adalah sebagai berikut:

- a. Penelitian ini memberikan kontribusi dalam pemilihan dan penerapan model *machine learning* yang sederhana namun efektif, seperti XGBoost, yang dapat menghasilkan prediksi yang akurat dengan waktu eksekusi yang cepat.
- b. Penelitian ini menyediakan pemahaman mengenai metode peramalan penjualan diluar metode tradisional yang umum digunakan dan menghasilkan metode peramalan penjualan yang dapat diimplementasikan secara praktis untuk mendukung pengambilan keputusan terkait pengendalian persediaan, seperti *safety stock* dan *reorder point*.
- c. Penelitian ini menyediakan pendekatan evaluasi model yang intuitif melalui penerapan metrik evaluasi yang tepat, yaitu MAPE dan RMSE, untuk

mengukur kesalahan dan memastikan kualitas prediksi penjualan dalam konteks bisnis.

- d. Penelitian ini berkontribusi pada validasi data yang lebih *robust* dengan menggunakan teknik validasi silang (*cross-validation*) untuk memastikan generalisasi model pada dataset yang berbeda.

1.7 Metodologi Penelitian

Penelitian ini terdiri atas tiga tahapan utama, yaitu pengumpulan data, peramalan penjualan, dan perhitungan *reorder point*.

1.7.1 Metode Pengumpulan Data

a. Studi Pustaka

Studi pustaka yang dilakukan untuk mengumpulkan informasi dari jurnal penelitian terdahulu yang relevan dengan topik yang menjadi objek penelitian.

b. Studi Lapangan

Studi lapangan dilakukan untuk mendapatkan sumber data primer melalui wawancara dan data sekunder melalui dokumentasi data perusahaan.

Wawancara dilakukan untuk memperdalam permasalahan yang akan dibahas dalam penelitian ini. Dokumentasi dilakukan untuk mendapatkan data historis penjualan pada dua outlet D'besto sebagai data yang akan dianalisis pada penelitian ini. Lalu dilakukan observasi pada situs web dengan tujuan untuk mengumpulkan data hari libur nasional. Observasi juga dilakukan pada ulasan Google untuk mendapatkan data pendukung.

1.7.2 Metode Peramalan Penjualan

Metode peramalan penjualan pada penelitian ini dilakukan dengan pendekatan *Knowledge Discovery In Databases* (KDD). KDD adalah proses sistematis yang melibatkan identifikasi, ekstraksi, dan pemahaman pola atau pengetahuan yang berharga dari data yang disimpan dalam basis data. Tujuan utama dari KDD adalah untuk mengungkap wawasan yang berguna dan berpotensi bermanfaat dari data, sehingga dapat digunakan untuk pengambilan keputusan yang lebih baik. Tahapan dari KDD:

- a. *Data Selection* (Seleksi Data): Tahap pertama KDD adalah memilih data yang relevan untuk analisis. Ini termasuk menentukan sumber data, jenis data yang akan digunakan, dan mengumpulkan data tersebut.
- b. *Data Preprocessing* (Pra-Pemrosesan Data): Data yang telah terpilih memerlukan pra-pemrosesan untuk dibersihkan dengan cara menghilangkan data yang tidak valid atau mengatasi masalah seperti duplikasi dan *missing values*. Tahapan ini juga meliputi proses ekstraksi fitur baru atau yang biasa disebut *feature engineering*.
- c. *Data Transformation* (Transformasi Data): Pada tahap ini, data yang telah dibersihkan dapat diubah ke format yang lebih sesuai untuk analisis, seperti normalisasi data atau mengubah data kategoris menjadi bentuk yang sesuai.
- d. *Train-test Split* (Pembagian Data *Training* dan *Testing*): Tahapan ini meliputi pembagian data untuk melatih (*training*) dan menguji (*testing*) model. Data *training* berguna untuk melatih model agar dapat menemukan

pola yang ada di data penjualan. Sedangkan data *testing* berguna untuk mengevaluasi performa model *machine learning*.

- e. *Data Mining* (Pemilihan dan Ekstraksi): Ini adalah tahap inti dari KDD, di mana algoritma *data mining* digunakan untuk mengidentifikasi pola, hubungan, atau informasi yang berguna dalam data. Ini bisa mencakup penggunaan teknik seperti regresi, *clustering*, klasifikasi, atau asosiasi untuk menggali wawasan. Pada penelitian ini, algoritma yang akan digunakan adalah XGBoost, dinilai dengan RMSE dan MAPE, dan dievaluasi ulang dengan *cross-validation*.
- f. *Evaluation/Interpretation* (Evaluasi/Interpretasi): Hasil dari *data mining* dievaluasi dan diinterpretasikan untuk memahami signifikansi wawasan yang ditemukan. Tahapan ini melibatkan pemahaman konteks dan penafsiran hasil.

1.7.3 Metode Perhitungan *Reorder Point*

- a. Perhitungan *Safety Stock*

Pada tahap ini dilakukan perhitungan *safety stock* dengan bantuan *tools* Microsoft Excel berdasarkan hasil peramalan penjualan yang telah dilakukan pada tahap sebelumnya.

- b. Perhitungan *Reorder Point*

Setelah perhitungan *safety stock* dilakukan, langkah selanjutnya adalah dilakukan perhitungan dengan bantuan *tools* Microsoft Excel untuk mengetahui titik *reorder point* produk *fried chicken*.

1.8 Sistematika Penulisan

Dalam penyusunan laporan penelitian, terbagi dalam lima bab yang meliputi pendahuluan, tinjauan pustaka, metodologi penelitian, hasil dan pembahasan dan penutup. Berikut penjelasan singkat terkait kelima bab tersebut:

BAB 1 PENDAHULUAN

Bab ini berisi penjelasan secara singkat mengenai latar belakang masalah, rumusan masalah, batasan masalah, tujuan dan manfaat penelitian, metodologi penelitian, dan sistematika penulisan.

BAB 2 TINJAUAN PUSTAKA

Bab ini membahas dasar-dasar teori beserta tinjauan pustaka yang mendukung penelitian ini sebagai acuan dalam melakukan penelitian terkait permasalahan yang diteliti.

BAB 3 METODOLOGI PENELITIAN

Bab ini menguraikan tentang metodologi yang digunakan dalam penelitian ini mulai dari metode pengumpulan data, metode peramalan penjualan data, dan metode lain yang digunakan serta kerangka dari penelitian yang dilakukan.

BAB 4 HASIL DAN PEMBAHASAN

Bab ini berisi pembahasan terkait dengan analisis data, pemrosesan data, evaluasi performa dari pemodelan data, hasil peramalan penjualan, hingga perhitungan *safety stock* dan *reorder point*.

BAB 5 PENUTUP

Bab ini berisi kesimpulan dari penelitian disertai saran-saran yang dapat digunakan sebagai acuan pada penelitian berikutnya.



Universitas Islam Negeri
YARIF HIDAYATULLAH JAKARTA



BAB 2

TINJAUAN PUSTAKA

2.1 Peramalan Penjualan

2.1.1 Pengertian Peramalan Penjualan

Peramalan atau *forecasting* merupakan ilmu untuk memperkirakan kejadian di masa depan. Peramalan dapat dilakukan dengan melibatkan pengambilan data historis dan memproyeksikannya untuk masa depan. Peramalan dilakukan dengan cara membentuk model matematis atau prediksi intuisi yang bersifat subjektif. Peramalan merupakan alat bantu yang sangat diperlukan bagi kebijakan perencanaan organisasi bisnis maupun pengambilan keputusan manajemen lainnya (Wiranda & Sadikin, 2019).

Peramalan penjualan merupakan proses estimasi atau prediksi mengenai jumlah penjualan suatu produk atau layanan dalam periode waktu tertentu di masa depan. Kegiatan ini dilakukan dengan memanfaatkan informasi yang dikumpulkan dan diinterpretasikan untuk mendukung pengambilan keputusan. Peramalan penjualan adalah dasar dari perencanaan anggaran dan operasional di hampir keseluruhan departemen perusahaan. Peramalan penjualan dapat membantu manajer dalam menyediakan dasar untuk merencanakan keputusan produksi di masa mendatang (Ekankumo, 2023).

2.1.2 Metode Peramalan Penjualan

Dalam melakukan peramalan penjualan, terdapat beberapa jenis metode yang digunakan. Beberapa metode tersebut dikelompokkan ke dalam dua jenis, yaitu metode kualitatif dan metode kuantitatif (Eby, 2020). Pembagian metode tersebut dapat dilihat pada Gambar 2.1.



Gambar 2.1 Metode Peramalan Penjualan

Metode kualitatif untuk peramalan penjualan didasarkan pada berbagai cara untuk menghasilkan opini yang tepat tentang prospek penjualan. Contoh metode kualitatif untuk peramalan penjualan adalah sebagai berikut:

- a. *Delphi Method*: Metode ini dilakukan dengan melakukan tanya jawab

dengan setiap ahli secara terpisah, kemudian menganalisis dan menyusun hasilnya. Hasilnya kemudian dikembalikan kepada para ahli dengan tujuan mempertimbangkan kembali jawaban mereka berdasarkan pandangan dan jawaban orang lain untuk mendapatkan hasil peramalan terbaik.

- b. Survei Pelanggan: Dengan pendekatan ini, dilakukan survei kepada pelanggan perusahaan tentang rencana pembelian para pelanggan. Kekurangan dari metode ini adalah biaya yang tinggi karena untuk membuat dan melakukan survei seperti ini sering kali memakan waktu dan biaya.

Peramalan penjualan dengan metode kuantitatif dilakukan dengan menggunakan data dan rumus atau model statistik untuk memproyeksikan penjualan di masa depan. Metode ini terbagi menjadi dua jenis yaitu metode *time series* atau deret waktu dan metode kausal. Metode *time series* menggunakan data historis penjualan saja. Sedangkan metode kausal melihat pada sebab dan akibat antara variabel yang berbeda dan pengaruhnya terhadap volume penjualan. Contoh metode peramalan penjualan dengan metode *time series* adalah sebagai berikut:

- a. *Moving Average* (MA): Teknik analisis untuk *time series* ini dilakukan dengan merata-ratakan titik data terbaru. Meskipun sangat umum digunakan, teknik ini dapat menghasilkan perkiraan yang halus dan kurang responsif terhadap volatilitas data.
- b. *Exponential Smoothing*: Metode ini menggunakan rata-rata dari data terbaru dengan bobot tertentu untuk meramalkan data berikutnya. Bobot yang lebih tinggi dimiliki oleh nilai terbaru dan untuk nilai yang lebih lama terjadi penurunan bobot secara bertahap.

- c. *Autoregressive Integrated Moving Average (ARIMA)*: Metode yang menggabungkan autoregresi dan *moving average*, serta menerapkan diferensiasi untuk menangani perubahan dalam data. ARIMA merupakan metode yang cukup umum digunakan untuk peramalan.

Selain metode *time series*, terdapat beberapa contoh teknik peramalan penjualan yang menggunakan metode kausal, yaitu sebagai berikut (Lazzeri, 2021):

- a. *Econometrics*: *Econometrics* merupakan metode dengan penggunaan model statistik dan matematika untuk mengembangkan teori atau menguji hipotesis yang ada dalam ekonomi dan untuk meramalkan tren masa depan dari data historis. Metode ini menguji data dunia nyata dalam uji statistik dan kemudian membandingkan hasilnya dengan teori yang diuji.
- b. *Multiple Regression*: Pendekatan pemodelan yang cukup penting dalam domain *machine learning* dan statistik. Dalam konteks *time series*, regresi digunakan untuk meramalkan nilai-nilai masa depan. Dalam *multiple regression*, digunakan kombinasi linear dari prediktor dan mempelajari bobot atau koefisien dari prediktor. Tujuannya adalah untuk menghasilkan garis regresi yang akan meramalkan nilai yang diprediksi. Metode ini cocok digunakan ketika variabel target bersifat numerik seperti peramalan penjualan. Beberapa model *multiple regression* yang sering digunakan adalah *Decision Tree*, *Random Forest*, *Neural Network*, *LightGBM* dan *XGBoost*.

2.2 *Machine Learning*


Machine learning merupakan bagian dari kecerdasan buatan yang mengizinkan sistem untuk meniru kemampuan manusia dalam belajar. Fokusnya adalah mengembangkan sistem atau algoritma yang dapat terus belajar dari data yang ada, meningkatkan akurasi seiring waktu tanpa memerlukan pemrograman khusus.

Dalam penerapannya, *machine learning* melibatkan pelatihan algoritma atau serangkaian proses statistik untuk mengidentifikasi pola dan fitur dalam kumpulan data yang besar. Tujuannya adalah untuk membuat keputusan atau prediksi berdasarkan informasi yang ditemukan. Semakin baik kinerja algoritmanya, semakin tinggi pula akurasi keputusan dan prediksi sistem (Yudhana *et al.*, 2022).

2.2.1 XGBoost

Extreme Gradient Boosting atau XGBoost merupakan salah satu metode *machine learning* yang digunakan dalam kasus klasifikasi atau regresi. XGBoost adalah sebuah algoritma yang menggunakan teknik *tree boosting*, yang dapat diperluas dan dikonfigurasi untuk membangun sistem yang lebih kompleks. XGBoost merupakan perkembangan dari metode *Gradient Boosting*, yaitu sebuah metode *ensemble* dari model yang berbasis pada *decision tree*. XGBoost bekerja dengan cara yang mirip dengan metode *Gradient Boosting* lainnya, yaitu dengan menggabungkan berbagai model *machine learning* untuk klasifikasi yang masih lemah. Penggabungan beberapa model ini bertujuan untuk meningkatkan performa melalui pelatihan bertahap. Hasil klasifikasi dari model *machine learning* sebelumnya yang disebut sebagai *residuals* atau *error* dijadikan bahan evaluasi agar

kinerja algoritma dengan metode *ensemble* ini meningkat (Gambar 2.2). Algoritma XGBoost dirancang untuk meningkatkan waktu eksekusi, terutama saat memproses data yang besar (Nugraha & Irawan, 2023).



Gambar 2.2 Ilustrasi Algoritma XGBoost

XGBoost secara bertahap memperbaiki kesalahan prediksi sebelumnya dengan menambahkan pohon-pohon baru ke dalam modelnya. Selain itu, dengan menggunakan fungsi tujuan yang teratur, XGBoost dapat mengoptimalkan modelnya untuk mencapai keseimbangan yang tepat antara presisi dan kompleksitas, yang membantu mencegah model dari *overfitting* pada data pelatihan. Fokus utama dalam XGBoost adalah pada penurunan nilai fungsi objektif teratur, yang didefinisikan sebagai berikut:

$$Obj(t) = \sum_{i=1}^t l(\hat{y}_i^t, y_i) + \sum_{i=1}^t \Omega(f_i) \quad (2.1)$$

Keterangan:

l = Fungsi *loss* atau nilai *error* dari prediksi

Ω = Fungsi regulasi atau kompleksitas model

\hat{y}_i^t = Nilai prediksi ke- i pada model *tree* ke- t

y_i = Nilai aktual ke- i

t = Total model *tree* yang dibangun dari *base tree models*

2.3 Persentase Kesalahan

Untuk mengukur hasil performa dari algoritma yang digunakan untuk peramalan, terdapat beberapa jenis metrik pengukuran yang umum digunakan. Contoh metrik pengukuran yang menggambarkan persentase dari kesalahan peramalan adalah *Root Mean Squared Error* (RMSE) dan *Mean Absolute Percentage Error* (MAPE) (Korstanje, 2021).

2.3.1 *Root Mean Squared Error* (RMSE)

RMSE adalah akar kuadrat dari kesalahan kuadrat rata-rata (*mean squared error*), sehingga skala kesalahan menjadi sama dengan skala target. Dalam konteks contoh peramalan penjualan, RMSE mengembalikan metrik kesalahan ke skala volume penjualan. Hal ini memudahkan untuk memahami kesalahan rata-rata dalam hal nilai aktual.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (\hat{y}_i - y_i)^2} \quad (2.2)$$

Keterangan:

\hat{y}_i = Nilai prediksi ke- i

y_i = Nilai aktual ke- i

n = Jumlah data

2.3.2 *Mean Absolute Percentage Error* (MAPE)

Mean Absolute Percentage Error atau MAPE dihitung dengan mengambil kesalahan untuk setiap prediksi, dibagi dengan nilai aktual. Hal ini dilakukan untuk mendapatkan kesalahan relatif terhadap nilai aktual. Metrik ini akan menghasilkan ukuran kesalahan dalam bentuk persentase. Oleh karena itu, kesalahan ini distandarisasi sehingga memudahkan interpretasi dari hasil perhitungan. Untuk

menghitung MAPE, diambil nilai absolut dari persentase kesalahan per baris dan menghitung rata-ratanya.

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{\hat{y}_i - y_i}{y_i} \right| \times 100\% \quad (2.3)$$

Keterangan:

\hat{y}_i = Nilai prediksi ke- i

y_i = Nilai aktual ke- i

n = Jumlah data

MAPE digunakan mengukur persentase kesalahan sehingga nilai MAPE yang lebih rendah adalah yang lebih baik. Sedangkan untuk melihat performa dari algoritma, maka perlu dilakukan perhitungan 1-MAPE. Hasil tersebut dapat diasumsikan sebagai kinerja atau performa dari algoritma yang dievaluasi.

2.4 Tools

Tools merupakan alat yang digunakan untuk mendukung sebuah penelitian. Dalam penelitian ini, beberapa *tools* digunakan dalam berbagai tahap mulai dari peramalan penjualan hingga perhitungan *reorder point*. Berikut adalah beberapa *tools* yang digunakan dalam penelitian ini:

2.4.1 Python

Python adalah bahasa pemrograman yang merupakan hasil dari upaya Guido van Rossum. Guido memulai pengembangan bahasa ini pada bulan Desember 1989 sebagai pengganti bahasa ABC. Awalnya, Python dimulai sebagai sebuah proyek dengan tujuan menciptakan sebuah bahasa yang cepat namun tetap fleksibel, dapat berjalan di berbagai platform, dan memberikan potensi pengembangan yang besar. Python berhasil menyediakan semua fitur ini dan

bahkan lebih.

Python berkembang menjadi bahasa pemrograman tingkat tinggi yang mudah digunakan pada banyak keperluan seperti untuk pengembangan berbagai aplikasi, analisis data, dan *machine learning*. Popularitas Python disebabkan oleh kesederhanaan, keterbacaan, dan pustaka yang luas, yang membuatnya menjadi pilihan ideal bagi para *data scientist dan developer*. Penggunaan Python untuk *machine learning* dapat diimplementasikan ke banyak kasus seperti *clustering*, asosiasi, klasifikasi, hingga peramalan (Muller & Massaron, 2019).

2.4.2 Google Colab

Google Colab merupakan sebuah *tools* gratis yang disediakan oleh Google dan dijalankan dengan teknologi komputasi awan. *Tools* ini memungkinkan pengguna untuk melakukan simulasi komputasi dengan dukungan penuh untuk Python dan berbagai *library* yang telah terpasang, serta menyimpan *file* secara langsung ke Google Drive. Proses penggunaan Google Colab untuk menjalankan Python cukup cepat dan mudah dilakukan. Google Colab memberikan akses yang praktis dan efisien untuk melakukan berbagai tugas komputasi tanpa perlu khawatir tentang pengaturan infrastruktur (Vieira, Alves, & Catarino, 2019).

2.4.3 Microsoft Excel

Microsoft Excel merupakan sebuah program *spreadsheet* yang terdapat dalam paket perangkat lunak Microsoft Office. Program ini merupakan salah satu produk pengolah data dari Microsoft yang dirancang dalam bentuk lembaran tabel tersebar (*spreadsheet*). Microsoft Excel dapat digunakan untuk membuat dan memformat *workbook*, melakukan analisis data, serta membuat data itu sendiri. Penelitian lain juga mengatakan bahwa Microsoft Excel merupakan perangkat

lunak yang dapat melakukan pengolahan data secara otomatis, mulai dari perhitungan dasar, penggunaan fungsi-fungsi, pembuatan grafik, dan hingga manajemen data (Ruqoyyah, Murni, & Linda, 2020).

2.5 Persediaan

Menurut Damanik, Meilano, & Tanto (2019), persediaan merupakan suatu aset yang berisi barang-barang milik perusahaan yang dimaksudkan untuk dijual selama periode tertentu. Persediaan juga dapat didefinisikan sebagai bahan yang terdapat dalam proses produksi atau yang telah disimpan untuk suatu tujuan menjalankan pekerjaan/proses produksi yang sedang berlangsung yang sedang menunggu untuk digunakan dalam proses produksi. Istilah persediaan sendiri didefinisikan dalam PSAK No.14 Tahun 2018 oleh Ikatan Akuntansi Indonesia (IAI) menjelaskan bahwa pengertian persediaan adalah aset:

- a. Tersedia untuk dijual dalam kegiatan usaha normal
- b. Dalam proses produksi dan atau dalam perjalanan
- c. Dalam bentuk bahan atau perlengkapan (*supplies*) untuk digunakan dalam proses produksi atau pemberian jasa.

Berdasarkan definisi diatas dapat disimpulkan bahwa persediaan adalah aset yang dimiliki perusahaan yang digunakan untuk dijual kembali kepada pelanggan. Untuk memastikan jumlah persediaan yang dimiliki perusahaan tetap optimal, setiap perusahaan perlu melakukan pengendalian persediaan. Pengendalian persediaan dapat meminimalisir kerugian akibat kelebihan persediaan ataupun kerugian akibat kehilangan potensi penjualan dikarenakan kekurangan persediaan.

2.5.1 *Safety Stock*

Dalam menjalankan kegiatan operasionalnya, perusahaan sering menghadapi jumlah permintaan pelanggan yang fluktuatif sehingga seringkali perusahaan tidak berhasil melakukan prediksi permintaan yang akurat. Untuk mengatasi hal tersebut, perusahaan biasanya memiliki tingkat persediaan tertentu sebagai cadangan, yang dikenal sebagai *safety stock*. *Safety stock* menunjukkan upaya perusahaan untuk selalu memiliki persediaan yang mencukupi, dengan tujuan mencegah kekurangan persediaan. Selain karena penggunaan persediaan yang melebihi perkiraan awal, kondisi *understock* bisa terjadi karena keterlambatan dalam pengiriman persediaan yang disimpan. Oleh karena itu, diperlukan perhitungan yang melibatkan waktu pengiriman persediaan atau yang biasa disebut *lead time* (Wanti *et al.*, 2020). Diperlukan juga *Z-score* dari *service level*/ tingkat keyakinan yang pada umumnya berada di angka 95%. Untuk menentukan jumlah *safety stock* yang dibutuhkan untuk suatu produk, dapat dilakukan dengan perhitungan berikut:

$$SS = \sigma_D \times Z \times \sqrt{L} \quad (2.4)$$

Keterangan:

SS = *Safety stock*

σ_D = Standar deviasi/pemakaian rata-rata (dari prediksi penjualan)

Z = Tingkat keyakinan yang diinginkan

L = *Lead time*

2.5.2 *Reorder Point (ROP)*

Reorder Point atau ROP adalah batas jumlah persediaan di mana pemesanan harus dilakukan ulang. Penentuan titik ini memperhatikan penggunaan persediaan

selama barang-barang yang dipesan belum tiba dan persediaan minimum yang harus dimiliki oleh perusahaan (Wanti *et al.*, 2020). Rumus yang digunakan untuk menentukan *reorder point* adalah sebagai berikut:

$$ROP = (\text{rata - rata prediksi penjualan} \times L) + SS \quad (2.5)$$

Keterangan:

SS = *Safety stock*

L = *Lead time*

Reorder point diperoleh dengan mengalikan *lead time* dengan jumlah penggunaan rata-rata ditambah persediaan pengamanan. Pada penelitian ini, hasil dari peramalan penjualan diasumsikan sebagai jumlah penggunaan rata-rata.

2.6 Literatur Sejenis

Peneliti melakukan studi literatur terhadap beberapa jurnal nasional serta internasional yang berkaitan dengan penelitian ini. Berikut adalah beberapa jurnal penelitian sejenis pada Tabel 2.1.

Tabel 2.1 Literatur Sejenis

Penulis	Judul	Metode & Hasil Penelitian	Kelebihan	Kekurangan
Niu (2020)	Walmart Sales Forecasting using XGBoost algorithm and Feature engineering	Penelitian ini menggunakan model prediksi penjualan XGBoost yang menggabungkan algoritma XGBoost dengan teknik <i>feature engineering</i> yang	Penelitian ini melakukan perbandingan algoritma XGBoost dengan algoritma Ridge. Data yang digunakan pada penelitian ini	Penelitian ini hanya dievaluasi dengan perhitungan RMSE saja tanpa adanya perhitungan persentase

		<p>cermat untuk memprediksi penjualan Walmart. Metode ini berhasil mencapai kinerja yang lebih unggul dibandingkan dengan pendekatan <i>machine learning</i> lainnya, dengan nilai RMSE yang lebih rendah 0.141 dan 0.113 dibandingkan dengan algoritma regresi <i>Logistic Regression</i> dan algoritma Ridge.</p>	<p>adalah data historis penjualan selama 3 tahun.</p>	<p>kesalahan lain seperti MAPE. Penelitian ini dilakukan terhadap industri ritel namun tidak menyertakan perhitungan terhadap <i>reorder point</i> dari produk yang diprediksi.</p>
<p>Massaro et al. (2021)</p>	<p><i>Augmented Data and XGBoost Improvement for Sales Forecasting in the Large-Scale Retail Sector</i></p>	<p>Penelitian ini menerapkan algoritma XGBoost dalam proyek industri untuk memprediksi penjualan produk, termasuk kondisi promosi dan analisis multiparameter. Hasilnya menunjukkan peningkatan signifikan dalam akurasi prediksi, dengan pengurangan kesalahan prediksi seperti <i>Root Mean Square Error</i> (RMSE) dan <i>Mean Square Error</i> (MSE) sekitar satu orde</p>	<p>Selain XGBoost, penelitian ini menggunakan teknik <i>Augmented Data</i> untuk melakukan peramalan penjualan. Penelitian ini juga disertai analisis terhadap kondisi promosi dan parameter tambahan lainnya.</p>	<p>Penelitian ini hanya dievaluasi dengan perhitungan RMSE dan MSE saja tanpa adanya perhitungan persentase kesalahan lain seperti MAPE. Penelitian ini tidak menyertakan perhitungan terhadap <i>reorder point</i>. Penelitian ini juga menggunakan jumlah data yang terbatas yaitu sebanyak 90 hari saja.</p>

		besarnya dengan menggunakan teknik <i>Augmented Data</i> .		
Wei & Zeng, (2021)	<i>Research on Sales Forecast based on XGBoost-LSTM Algorithm Model</i>	Penelitian ini membangun model gabungan XGBoost-LSTM untuk peramalan penjualan dengan data penjualan <i>supermarket chain</i> selama 3 tahun. Hasilnya menunjukkan akurasi lebih tinggi dibanding model deret waktu klasik, memberikan dasar ilmiah bagi strategi pemasaran dan nilai komersial yang besar.	Penelitian ini melakukan perbandingan algoritma XGBoost dengan algoritma <i>Long Short-Term Memory</i> (LSTM). Data yang digunakan pada penelitian ini adalah data historis penjualan selama 3 tahun.	Penelitian ini tidak menyertakan perhitungan terhadap <i>reorder point</i> . Penelitian ini juga terbatas pada analisis <i>time-series</i> saja dan tidak mempertimbangkan variabel lain seperti hari libur nasional.
Zhang et al. (2021)	<i>Time Series Forecast of Sales Volume Based on XGBoost</i>	Penelitian ini bertujuan untuk melakukan peramalan penjualan pada industri ritel menggunakan teknik <i>feature engineering</i> untuk memprediksi volume penjualan di masa depan dengan XGBoost dan empat algoritma lainnya yaitu LSTM, ARIMA, GBDT, dan Prophet. Hasil eksperimen menunjukkan	Penelitian ini tidak hanya terbatas pada penggunaan algoritma XGBoost saja. Dalam penelitian ini dilakukan pengujian terhadap empat algoritma lain yaitu LSTM, ARIMA, GBDT, dan Prophet. Penelitian ini juga menyertakan banyak variabel dependen seperti kualitas air, suhu,	Penelitian ini tidak menyertakan perhitungan terhadap <i>reorder point</i> yang umumnya diperlukan pada industri ritel.

		performa XGBoost lebih baik dan efisien daripada model lainnya.	hari libur, dan variabel lainnya.	
Turgut & Erdem, (2022)	<i>Forecasting of Retail Produce Sales Based on XGBoost Algorithm</i>	Penelitian ini membandingkan kinerja prediksi penjualan buah dan sayuran menggunakan metode statistik tradisional dan metode <i>machine learning</i> . Metode SARIMA digunakan sebagai pendekatan statistik tradisional, sementara algoritma LSTM dan XGBoost digunakan sebagai metode <i>machine learning</i> . Hasilnya menunjukkan bahwa algoritma XGBoost memberikan hasil yang lebih akurat dibandingkan dengan dua metode lainnya.	Penelitian ini tidak hanya menggunakan algoritma XGBoost saja melainkan membandingkan dengan metode <i>machine learning</i> lain yaitu LSTM dan metode tradisional yaitu SARIMA. Analisis yang dilakukan juga tidak terbatas pada hari libur saja melainkan terdapat variabel lain seperti suhu, musim, dan variabel dependen lainnya.	Penelitian ini dilakukan terhadap buah dan sayuran dimana kesegaran dari produk harus terjamin, namun dalam penelitian ini tidak disertakan pengendalian persediaan untuk produk tersebut seperti perhitungan <i>reorder point</i> dan <i>safety stock</i> .
Santos (2020)	<i>Reorder Point Definition Through Demand Forecasting To Manage Stock Levels</i>	Studi ini dilakukan di Alpha, sebuah perusahaan pengecer di bidang pipa dan sistem pemanas, dengan tujuan mengurangi tingkat inventaris untuk membebaskan aliran kas untuk investasi	Dalam pengelolaan persediaan, penelitian ini melakukan perhitungan <i>Economic Order Quantity</i> (EOQ) untuk menentukan jumlah pesanan bahan baku dengan	Penelitian ini masih menggunakan metode tradisional dalam melakukan peramalan. Metode yang digunakan adalah metode <i>time-series</i> yaitu Holt Winters

		<p>masa depan. Setelah menganalisis indikator persediaan, disimpulkan bahwa tingkat inventaris tidak sesuai dengan permintaan dan ada ruang untuk perbaikan. Dengan mengadopsi model manajemen inventaris baru berdasarkan Holt Winters <i>Exponential Smoothing</i> dengan nilai MAPE sebesar 12,76%, berhasil mengurangi tingkat inventaris sekitar 42% dan menghemat sekitar 220,000 euro per tahun.</p>	<p>biaya terendah. Selain perencanaan pengendalian persediaan, penelitian ini juga menyertakan simulasi dari penerapan sistem peramalan penjualan dan perhitungan <i>reorder point</i> sehingga menghasilkan angka peningkatan level inventasi sebesar 42%. Data yang digunakan pada penelitian ini adalah data penjualan selama 18 bulan.</p>	<p><i>exponential smoothing</i>, dimana metode ini tidak dapat mempertimbangkan variabel lain seperti hari libur nasional. Untuk metrik evaluasi yang digunakan pada penelitian ini hanya MAPE saja tanpa disertai metrik lain seperti RMSE.</p>
<p>Tanama I, Nurdiansyah, & Firdaus (2020)</p>	<p><i>Inventory Support System for Retail Shop</i></p>	<p>Penelitian ini bertujuan untuk membuat prosedur peramalan jumlah pemesanan ulang untuk setiap item yang dipilih dalam bisnis ritel, khususnya di toko XYZ yang menjual kebutuhan rumah tangga sehari-hari. Menggunakan metode <i>simple exponential smoothing</i> dengan</p>	<p>Penelitian ini menggunakan <i>Mean Absolute Deviation</i> (MAD) sebagai metrik evaluasi. Selain melakukan peramalan penjualan, penelitian ini juga menyertakan desain sistem <i>inventory management</i> untuk toko XYZ.</p>	<p>Data yang digunakan pada penelitian ini terbatas pada data penjualan selama 12 bulan saja. Penelitian ini juga tidak menyertakan RMSE sebagai metrik evaluasi. Penggunaan metode peramalan pada penelitian ini masi tradisional yaitu analisis <i>time-</i></p>

		konstanta penyamarataan 0,2, penelitian ini berhasil mengendalikan sistem manajemen inventaris yang lebih baik.		<i>series</i> dengan metode <i>simple exponential smoothing</i> .
Silaen & Iskanda r (2023)	<i>Inventory Management with Demand Forecast For Eyeglass Lenses Using the Time Series Method at An Optical Store</i>	Penelitian ini memfokuskan pada pengendalian inventaris pada toko optik. Dengan menggunakan beberapa metode <i>time-series</i> , seperti model <i>Cyclical</i> , <i>Cyclical Trend</i> , dan ARIMA (1,0,3), penelitian ini berhasil melakukan peramalan permintaan dengan periode bulanan masa depan pada produk lensa dan menentukan jumlah <i>safety stock</i> serta <i>reorder point</i> . Hasilnya menunjukkan bahwa model <i>Cyclical Trend</i> adalah yang paling tepat untuk memprediksi permintaan, dengan <i>service level</i> 90%.	Penelitian ini dilakukan dengan membandingkan tiga algoritma untuk peramalan penjualan. Metrik evaluasi yang digunakan lebih lengkap karena terdiri dari <i>Mean Squared Error</i> (MSE), MAD, dan MAPE. Penelitian ini juga menyertakan perhitungan terhadap <i>service level</i> yang meningkat yaitu sebesar 90% setelah dilakukan peramalan permintaan.	Data yang digunakan terbatas hanya sebanyak 10 bulan saja. Penelitian ini menggunakan metode <i>time-series</i> tradisional dimana metode ini tidak dapat mempertimbangkan variabel lain seperti hari libur nasional.
Doresdi ana, Sugiyon	<i>Spare Parts Demand Forecasting</i>	Penelitian ini dilakukan dengan menggunakan metode	Metrik evaluasi yang digunakan lebih lengkap	Penelitian ini menggunakan metode <i>time-series</i>

o, & Saluy (2021)	<i>During Covid-19 pandemic (Automotive Company Case Study)</i>	kuantitatif yaitu dengan menggabungkan studi literatur, wawancara, dan mengumpulkan data sampel. Penelitian ini menggunakan metode <i>triple exponential smoothing</i> untuk melakukan peramalan permintaan dengan periode bulanan. Penelitian ini menghasilkan perhitungan <i>safety stock</i> dan <i>reorder point</i> untuk periode Juli 2020, yaitu terdapat 4 jenis produk yang persediaannya berada dibawah <i>reorder point</i> dan harus segera dilakukan pemesanan ulang.	karena terdiri dari <i>Mean Squared Error</i> (MSE), MAD, dan MAPE. Penelitian ini dilakukan terhadap 13 jenis produk.	tradisional yaitu <i>triple exponential smoothing</i> , dimana metode ini tidak dapat mempertimbangkan variabel lain seperti hari libur nasional. Data yang digunakan terbatas hanya sebanyak 12 bulan saja.
Nissa, Supian, & Nahar (2023)	<i>Inventory Control for MSME Products Using the Q Model with Lost Sales Condition Based on Products Sales Forecasting</i>	Penelitian ini bertujuan untuk membantu mengatasi masalah inventaris di MSME Sabun Bening Official dengan menggunakan metode peramalan Holt-Winter Exponential Additive untuk memprediksi	Peramalan penjualan pada penelitian ini dilakukan terhadap tiga jenis produk yang berbeda. Selain <i>safety stock</i> dan <i>reorder point</i> , penelitian ini menyertakan	Data penjualan yang digunakan dalam penelitian ini hanya terbatas dalam 7 bulan saja. Penelitian ini juga tidak menyertakan RMSE sebagai metrik evaluasi. Penelitian ini

	<p>permintaan produk di masa depan yang memiliki pola musiman dan tren. Setelah memperoleh nilai ramalan permintaan produk, dilakukan perhitungan pengendalian inventaris menggunakan metode inventaris probabilistik Q Model dengan kondisi kehilangan penjualan. Hasil penelitian menunjukkan bahwa metode peramalan Holt-Winter <i>Exponential Additive</i> adalah metode yang baik untuk memprediksi permintaan produk, dengan nilai MAPE kurang dari 20% untuk produk sabun tangan, pelembut, dan deterjen.</p>	<p>perhitungan <i>Economic Order Quantity</i> (EOQ) dan menggunakan metode inventaris probabilistik Q Model. Selain itu, penelitian ini juga memberikan kebijakan pengendalian inventaris yang optimal, termasuk jumlah pesanan produk, dan biaya total inventaris yang diharapkan.</p>	<p>menggunakan metode <i>time-series</i> tradisional yaitu Holt-Winter <i>Exponential Additive</i>, dimana metode ini tidak dapat mempertimbangkan variabel lain seperti hari libur nasional.</p>
--	--	---	---



BAB 3

METODOLOGI PENELITIAN

3.1 Pendekatan Penelitian

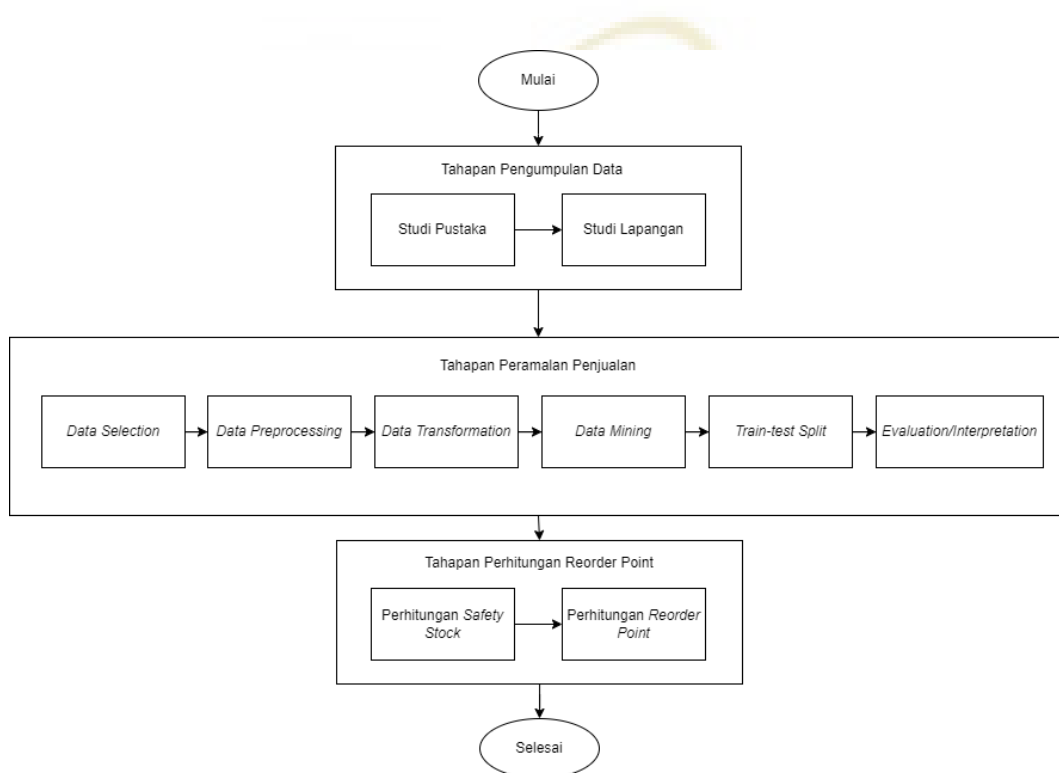
Penelitian ini menganalisis data penjualan harian produk *fried chicken* pada outlet D'besto GDC periode Januari 2023–Juni 2024 dengan tujuan melakukan peramalan penjualan untuk enam bulan kedepan yaitu Juli–Desember 2024. Penelitian ini melibatkan data pendukung analisis peramalan berupa data hari libur nasional pada periode Januari 2023–Desember 2024.

Proses peramalan penjualan pada penelitian ini dilakukan dengan pendekatan *Knowledge Discovery In Databases* (KDD). KDD adalah proses sistematis yang melibatkan identifikasi, ekstraksi, dan pemahaman pola atau pengetahuan yang berharga dari data yang disimpan dalam basis data. Pendekatan KDD ini terdiri dari tahap *data selection*, *data preprocessing*, *data transformation*, *data mining*, dan *evaluation/interpretation*. Pada tahapan *data mining*, algoritma *machine learning* yang digunakan adalah XGBoost dan pengukuran kesalahan dilakukan dengan *Root Mean Squared Error* (RMSE) dan *Mean Absolute Percentage Error* (MAPE).

Penelitian ini menggunakan Google Colab untuk menjalankan bahasa pemrograman Python yang digunakan selama tahapan pemrosesan data, analisis data, hingga pembuatan model *machine learning*. Sedangkan untuk menyusun laporan penelitian ini, peneliti menggunakan Microsoft Word dan bantuan Mendeley Desktop untuk menyusun daftar referensi yang digunakan.

3.2 Tahapan Penelitian

Penelitian ini terdiri atas tiga tahapan utama, yaitu tahapan pengumpulan data, peramalan penjualan, dan perhitungan *reorder point*. Tahapan-tahapan ini dilakukan secara berurut dan sistematis untuk memperoleh tujuan dari penelitian ini sendiri. Untuk alur dari tahapan penelitian ini dapat dilihat pada Gambar 3.1.



Gambar 3.1 Tahapan Penelitian

3.3 Deskripsi Tahapan Penelitian

Berdasarkan diagram alir tahapan penelitian pada Gambar 3.1, maka dapat di deskripsikan masing-masing dari tahap penelitian adalah sebagai berikut:

3.3.1 Studi Pustaka

Studi pustaka yang dilakukan untuk mengumpulkan informasi yang relevan dengan topik yang menjadi objek penelitian. Sumber studi pustaka yang dilakukan

berupa jurnal penelitian terdahulu. Informasi tersebut berkaitan dengan peramalan penjualan, algoritma XGBoost, dan teknik perhitungan *reorder point*. Peneliti juga mengumpulkan 10 literatur sejenis dengan periode 5 tahun terakhir untuk dikaji dari segi metode dan hasil penelitian, sehingga diperoleh kelebihan dan kekurangan dari penelitian tersebut dibandingkan dengan penelitian ini.

3.3.2 Studi Lapangan

Studi lapangan dilakukan untuk mendapatkan sumber data primer melalui wawancara dan data sekunder melalui dokumentasi dan observasi.

- a. Wawancara dilakukan untuk memperdalam permasalahan yang akan dibahas dalam penelitian ini. Metode wawancara semi terstruktur dilakukan bersama narasumber yang merupakan Kepala Resto D'besto GDC, yaitu Bapak Rival, pada Kamis, 19 November 2023. Wawancara ini menghasilkan informasi mengenai permasalahan terkait kondisi *overstock* yang sering terjadi di outlet ini. Hasil dari wawancara ini mendukung penulis dalam penyusunan latar belakang.
- b. Dokumentasi dilakukan untuk mendapatkan data historis penjualan harian pada outlet D'besto GDC dan D'besto Tapos sebagai data yang akan dianalisis pada penelitian ini. Data yang dikumpulkan terbatas pada produk *fried chicken* pada periode Januari 2023–Juni 2024.
- c. Observasi dilakukan untuk mendapatkan data pendukung penelitian. Observasi pertama dilakukan pada situs web *Public Holidays Global*, yang dapat diakses melalui <https://publicholidays.co.id/>, dengan tujuan untuk mengumpulkan data hari libur nasional pada periode Januari 2023–

Desember 2024. Observasi lainnya dilakukan pada ulasan Google untuk mendapatkan komentar pengguna mengenai kondisi *understock* yang beberapa kali terjadi.

3.3.3 *Data Selection (Seleksi Data)*

Pada tahapan ini dilakukan pemilihan data yang relevan untuk analisis. Ini termasuk menentukan sumber data, jenis data yang akan digunakan, dan mengumpulkan data tersebut. Data yang akan digunakan dalam penelitian ini terdiri dari data endogen dan data eksogen. Data endogen merupakan data atau variabel yang secara langsung dipengaruhi oleh variabel lain dalam sistem yang dimodelkan. Sedangkan data eksogen adalah data atau variabel yang tidak secara langsung dipengaruhi oleh variabel lain dalam sistem.

Pada tahapan ini, dilakukan seleksi data penjualan harian khusus untuk produk *fried chicken* periode Januari 2023–Juni 2024 pada outlet D’besto GDC dan D’besto Tapos sebagai data atau variabel endogen. Sedangkan untuk data eksogen yang digunakan untuk membantu analisis adalah data hari libur nasional pada periode Januari 2023–Desember 2024. Data hari libur nasional periode Januari 2023–Juni 2024 digunakan untuk pelatihan dan pengujian model, sedangkan untuk periode Juli–Desember 2024 digunakan untuk peramalan penjualan pada periode tersebut.

3.3.4 *Data Preprocessing (Pra-Pemrosesan Data)*

Data yang telah terpilih memerlukan pra-pemrosesan untuk dibersihkan dengan cara menghilangkan data yang tidak valid, anomali data, dan mengatasi masalah seperti *missing values* dan *duplicated data*. *Missing values* adalah

informasi yang tidak tersedia dalam sebuah data. Data yang tidak memiliki *value* atau nilai ini biasa disebut *null*. *Missing values* dalam skenario peramalan penjualan perlu diisi dengan nilai lain. Dalam kasus yang sederhana, seperti presentase *missing values* dibawah 5% atau distribusi data mendekati normal atau sama dengan normal, maka *missing values* dapat diganti dengan rata-rata dari keseluruhan penjualan (Tawn, Browell, & Dinwoodie, 2020).

Duplicated data adalah data yang terduplikasi. Jenis data seperti ini perlu dihapus agar tidak mengganggu proses pengembangan model. Setelah melakukan pembersihan data, selanjutnya dilakukan tahapan *feature engineering*. *Feature engineering* merupakan proses mengubah atau menambah fitur atau kolom baru yang relevan dengan analisis yang dibutuhkan. Proses ini dilakukan untuk meningkatkan kualitas representasi data dan performa model *machine learning*. Pada penelitian ini akan dilakukan penambahan beberapa fitur baru yang diekstraksi dari data tanggal penjualan harian.

3.3.5 Data Transformation (Transformasi Data)

Pada tahap ini, data yang telah dibersihkan dapat diubah ke format yang lebih sesuai untuk analisis, seperti normalisasi data atau mengubah data kategoris menjadi bentuk yang sesuai. Untuk peramalan penjualan menggunakan algoritma XGBoost, variabel tanggal penjualan perlu dijadikan *index* kolom. Sehingga, tahapan ini meliputi perubahan kolom tanggal menjadi *index*. Perubahan ini perlu dilakukan dengan tujuan memastikan bahwa data terurut secara kronologis dan memudahkan model *machine learning* untuk membaca pola yang ada.

3.3.5 *Train-test Split* (Pembagian Data *Training* dan Data *Testing*)

Pada tahapan ini, dilakukan proses pembagian data untuk melatih (*training*) dan menguji (*testing*) model dengan rasio 80:20, di mana 80% dari keseluruhan dataset digunakan untuk melatih model agar dapat mengenali pola dan hubungan antar variabel, sementara 20% sisanya disisihkan untuk pengujian. Data pengujian ini berfungsi sebagai alat evaluasi guna mengukur seberapa baik model dapat memprediksi data baru yang belum pernah dilihat sebelumnya, sehingga membantu dalam mengidentifikasi potensi *overfitting* atau *underfitting*. Pendekatan ini penting untuk memastikan bahwa model memiliki kemampuan generalisasi yang baik pada data *real-world* di luar sampel pelatihan.

3.3.6 *Data Mining* (Pemilihan dan Ekstraksi)

Tahapan ini merupakan tahapan inti, di mana algoritma *data mining* digunakan untuk mengidentifikasi pola, hubungan, atau informasi yang berguna dalam data. Ini bisa mencakup penggunaan teknik seperti regresi, *clustering*, klasifikasi, atau asosiasi untuk menggali wawasan. Pada penelitian ini, algoritma yang akan digunakan adalah XGBoost. Penelitian ini menggunakan *library* XGBoost dan memanfaatkan *default parameter* yang sudah tersedia. Pada penelitian ini tidak dilakukan *hyperparameter tuning* karena tujuan penelitian ini untuk membuat model peralaman penjualan yang dapat digunakan setiap hari, sehingga kecepatan eksekusi menjadi fokus penting. *Hyperparameter tuning* dapat meningkatkan performa namun memberikan waktu eksekusi yang lama dan tidak efektif untuk penggunaan harian. *Default parameter* dari XGBoost juga terbukti memberikan performa yang cukup baik tanpa *hyperparameter tuning*. Sehingga

penelitian ini tidak mengikutsertakan proses hyperparameter tuning yang biasanya memakan waktu berjam-jam bahkan lebih dari satu hari. dan dinilai dengan RMSE dan MAPE. Angka MAPE untuk skenario peramalan penjualan yang berada di kisaran 0–10% tergolong sangat baik, sedangkan skor 10–20% tergolong baik (Tabel 3.1).

Tabel 3.1 Kriteria MAPE

MAPE	Pengertian
<10%	Kemampuan Peramalan Sangat Baik
10%–20%	Kemampuan Peramalan Baik
20%–50%	Kemampuan Peramalan Layak
>50%	Kemampuan Peramalan Buruk

Selanjutnya adalah melakukan *cross-validation*, dimana data akan dibagi kedalam beberapa bagian atau lipatan (*folds*) dengan tujuan melakukan pengujian berulang terhadap RMSE dan MAPE dengan data *testing* yang berbeda-beda. Hal ini dilakukan untuk menghindari *overfitting*, yaitu kondisi dimana model *machine learning* terlalu kompleks dan menangkap *noise* dalam data *training*, sehingga performanya tidak baik pada data baru. Rata-rata skor RMSE dan MAPE dari keseluruhan pengujian menggunakan *cross-validation* menjadi skor akhir yang dapat merepresentasikan performa model *machine learning* secara keseluruhan. Pada tahapan ini juga dilakukan peramalan untuk periode enam bulan kedepan yang nantinya akan menjadi acuan untuk tahap perhitungan *reorder point*.

3.3.7 Evaluation/Interpretation (Evaluasi/Interpretasi)

Hasil dari *data mining* dievaluasi dan diinterpretasikan untuk memahami

signifikansi wawasan yang ditemukan. Tahapan ini juga meliputi pengecekan nilai *feature importance* untuk menghasilkan pemahaman mengenai variabel apa yang memiliki pengaruh paling besar terhadap volume penjualan harian. *Feature importance* adalah konsep dalam *machine learning* yang mengukur kontribusi relatif dari setiap fitur terhadap hasil prediksi dari suatu model. Dalam algoritma XGBoost, *feature importance* dihitung berdasarkan seberapa sering fitur digunakan dalam *decision tree* atau pohon keputusan selama proses pelatihan model *machine learning*.

3.3.8 Perhitungan *Safety Stock*

Pada tahap ini dilakukan perhitungan *safety stock* dengan bantuan *tools* Microsoft Excel berdasarkan hasil peramalan penjualan yang telah dilakukan pada tahap sebelumnya. Perhitungan *safety stock* akan menggunakan standar deviasi dari keseluruhan penjualan dengan *service level* di angka 95% atau *Z-score* sebesar 1,64.

3.3.9 Perhitungan *Reorder Point*

Setelah perhitungan *safety stock* dilakukan, langkah selanjutnya adalah dilakukan perhitungan dengan bantuan *tools* Microsoft Excel untuk mengetahui titik *reorder point* produk *fried chicken*.

3.4 Waktu Penelitian

Penelitian dilakukan dengan melalui beberapa tahapan penelitian seperti identifikasi masalah, studi literatur, metodologi penelitian, dan analisis hasil penelitian. Secara spesifik tahapan penelitian yang dilakukan digambarkan dalam

Tabel 3.2.

Tabel 3.2 Waktu Penelitian

	11/ 2023	12/ 2023	01/ 2024	02/ 2024	03/ 2024	04/ 2024	05/ 2024	06/ 2024	07/ 2024
Identifikasi Masalah									
Studi Literatur									
Metodologi Penelitian									
Analisis Hasil Penelitian									



Universitas Islam Negeri
YARIF HIDAYATULLAH JAKARTA



BAB 4

HASIL DAN PEMBAHASAN

4.1 *Data Selection (Seleksi Data)*

Pada tahapan ini, dilakukan seleksi data untuk peramalan penjualan yang menghasilkan dua jenis data, yaitu:

- a. Data Endogen: Data endogen yang digunakan pada penelitian ini adalah data penjualan harian yang diperoleh dari database penjualan pada outlet D'besto GDC dan D'besto Tapos.
- b. Data Eksogen: Data eksogen yang digunakan untuk mendukung analisis pada penelitian ini adalah data hari libur nasional yang diperoleh dari hasil observasi pada situs web *Public Holidays Global*.

Data yang digunakan adalah data penjualan produk *fried chicken* periode Januari 2023–Juni 2024 pada outlet D'besto GDC dan D'besto Tapos (Tabel 4.1).

Tabel 4.1 Sampel Data Penjualan Harian *Fried Chicken* pada outlet D'besto GDC dan Tapos

Date	GDC_sales	Tapos_sales
1/1/2023	583	488
2/1/2023	539	378
3/1/2023	433	343
4/1/2023	457	292
5/1/2023	369	294
6/1/2023	487	291
7/1/2023	369	322
8/1/2023	513	375
9/1/2023	418	248
10/1/2023	395	246

Kolom ‘*Date*’ mengacu pada tanggal penjualan harian. Kolom ‘*GDS_sales*’ menunjukkan penjualan harian produk *fried chicken* di outlet D’besto GDC. Sedangkan kolom ‘*Tapos_sales*’ menunjukkan penjualan harian produk *fried chicken* di outlet D’besto Tapos. Pada tahap ini juga dilakukan pembuatan *file* data hari libur nasional pada periode Januari 2023–Desember 2024 dengan menggunakan Microsoft Excel (Tabel 4.2).

Tabel 4.2 Sampel Data Hari Libur Nasional

Tanggal	Hari Libur
1/1/2023	Tahun Baru Masehi
22/1/2023	Tahun Baru Imlek
23/1/2023	Cuti Bersama Tahun Baru Imlek
18/2/2023	Isra Mikraj
22/3/2023	Hari Suci Nyepi
23/3/2023	Cuti Bersama Hari Suci Nyepi
7/4/2023	Jumat Agung
19/4/2023	Cuti Bersama Lebaran
20/4/2023	Cuti Bersama Lebaran
21/4/2023	Cuti Bersama Lebaran
22/4/2023	Hari Raya Idul Fitri
23/4/2023	Cuti Bersama Lebaran
24/4/2023	Cuti Bersama Lebaran
25/4/2023	Cuti Bersama Lebaran
1/5/2023	Hari Buruh
18/5/2023	Kenaikan Isa Almasih

Data penjualan harian dari kedua outlet digabungkan dengan data hari libur nasional. Data hari libur diganti dengan kolom ‘*Holiday*’, dimana angka 1 menunjukkan bahwa tanggal tersebut merupakan hari libur nasional dan angka 0 menunjukkan bahwa tanggal tersebut bukan merupakan hari libur nasional (Gambar

4.1).

	Date	Holiday	GDC_sales	Tapos_sales
0	2023-01-01	1	583	488
1	2023-01-02	0	539	378
2	2023-01-03	0	433	343
3	2023-01-04	0	457	292
4	2023-01-05	0	369	294
...
542	2024-06-26	0	485	259
543	2024-06-27	1	393	342
544	2024-06-28	0	567	350
545	2024-06-29	1	504	390
546	2024-06-30	1	518	353

Gambar 4.1 Data Penjualan dan Hari Libur Nasional

4.2 Data Preprocessing (Pra-Pemrosesan Data)

Sebelum melakukan *data pre-processing*, dilakukan pengecekan informasi mengenai data, statistik deskriptif, *missing values* (nilai yang kosong), dan *duplicated data* (data yang terduplikasi). Pengecekan data ini hanya dilakukan pada data yang akan digunakan untuk pemodelan saja, yaitu data periode Januari 2023–Juni 2024.

Gambar 4.2 menunjukkan bahwa tipe data dari setiap kolom sudah sesuai dengan nilainya sehingga tidak memerlukan perubahan. Gambar 4.2 juga menunjukkan bahwa terdapat *missing values* pada kolom ‘*GDC_sales*’ dan ‘*Tapos_sales*’. Sedangkan untuk *duplicated data*, tidak ditemukan data yang terduplikasi pada data ini berdasarkan pengecekan yang dilakukan.

```
def data_desc(dataframe):
    print("DATA DESCRIPTION")
    print('-'*80)
    print("Shape of dataset : ",dataframe.shape)
    print('-'*80)
    print(dataframe.info())
    print('-'*80)
    print(dataframe.describe(exclude = 'datetime64').T)
    print('-'*80)
    print("Is there any duplicated data :",df.duplicated().any())
    print('-'*80)
    print("MISSING VALUES IN %")
    print('-'*80)
    print(round(100* (dataframe.isnull().sum() / len(dataframe))
    .sort_values(ascending=False),1))
data_desc(df)
```

```
DATA DESCRIPTION
-----
Shape of dataset : (547, 4)
-----
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 547 entries, 0 to 546
Data columns (total 4 columns):
#   Column      Non-Null Count  Dtype
---  ---
0   Date         547 non-null    datetime64[ns]
1   Holiday      547 non-null    int64
2   GDC_sales    543 non-null    float64
3   Tapos_sales  543 non-null    float64
dtypes: datetime64[ns](1), float64(2), int64(1)
memory usage: 17.2 KB
None
-----

```

	count	mean	std	min	25%	50%	75%	\
Holiday	547.0	0.095064	0.293572	0.0	0.000	0.0	0.0	
GDC_sales	543.0	442.929236	66.068492	245.0	397.000	434.0	483.0	
Tapos_sales	543.0	325.134945	70.901397	187.0	273.525	319.0	364.0	

```

max
Holiday      1.00
GDC_sales    660.00
Tapos_sales  659.75
-----
Is there any duplicated data : False
-----
MISSING VALUES IN %
-----
GDC_sales    0.7
Tapos_sales  0.7
Date         0.0
Holiday      0.0
dtype: float64

```

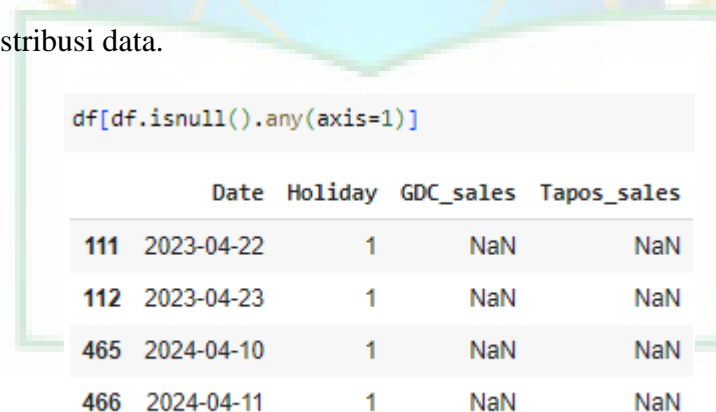
Gambar 4.2 Kode dan Hasil Deskripsi Data

Gambar 4.2 juga menunjukkan bahwa tipe data dari setiap kolom sudah sesuai dan tidak ada anomali data. Oleh karena itu, tahapan yang perlu dilakukan selanjutnya adalah mengatasi *missing values*.

4.2.1 Handling Missing Values

Tahapan ini diawali dengan pengecekan *missing values* atau baris dengan nilai kosong. Pada data yang digunakan ini ditemukan dua *missing values* pada hari yang sama. *Missing values* dalam kasus peramalan atau *forecasting* perlu diatasi dengan cara diisi dengan nilai lain dan tidak boleh dihapus barisnya.

Hasil dari pengecekan *missing values* menunjukkan bahwa kolom ‘GDC_sales’ dan ‘Tapos_sales’ memiliki *missing values* pada baris yang sama, yaitu pada tanggal 22–23 April 2023 dan 10–11 April 2024 (Gambar 4.3). Keempat hari tersebut bertepatan dengan hari libur nasional. Untuk menentukan tindakan apa yang perlu dilakukan untuk mengatasi *missing values* ini, diperlukan pengecekan terhadap distribusi data.




```
df[df.isnull().any(axis=1)]
```

	Date	Holiday	GDC_sales	Tapos_sales
111	2023-04-22	1	NaN	NaN
112	2023-04-23	1	NaN	NaN
465	2024-04-10	1	NaN	NaN
466	2024-04-11	1	NaN	NaN

Gambar 4.3 Kode dan Hasil Pengecekan *Missing Values*

Gambar 4.4 menunjukkan bahwa kolom ‘GDC_sales’ dan ‘Tapos_sales’ memiliki distribusi yang mendekati normal. Hal ini juga ditunjukkan oleh angka *mean* dan *median* dari masing-masing kolom yang memiliki selisih kecil. Selain itu, *missing values* pada data ini sangat sedikit, yaitu sebesar 0.7% dari total data (Gambar 4.2). Oleh karena itu dapat disimpulkan bahwa penanganan *missing values*

pada data ini dapat dilakukan dengan mengganti nilai yang kosong dengan rata-rata penjualan di masing-masing outlet, karena skenario *missing values* ini dinilai cukup sederhana. Oleh karena itu, dilakukan pengisian nilai yang kosong dengan rata-rata penjualan harian di hari libur pada masing-masing outlet karena data yang kosong tersebut bertepatan dengan hari libur. Hal ini bertujuan untuk mempertahankan pola dan dapat merepresentasikan nilai yang lebih akurat.



Gambar 4.4 Distribusi Data Penjualan D'besto GDC & Tapos

Gambar 4.5 menunjukkan hasil dari penanganan *missing values* setelah dilakukan pengisian nilai dengan rata-rata penjualan di hari libur untuk masing-masing outlet. Dengan pengisian nilai tersebut, dapat dilihat bahwa data ini sudah tidak lagi memiliki *missing values* yang dapat mengganggu proses peramalan penjualan.

```
df['GDC_sales'].fillna(df.groupby('Holiday')
['GDC_sales'].mean().round(0)[1], inplace=True)
df['Tapos_sales'].fillna(df.groupby('Holiday')
['Tapos_sales'].mean()[1].astype(int), inplace=True)

print("Average Sales on Holiday")
print(df.groupby('Holiday').agg({'GDC_sales': 'mean', 'Tapos_sales': 'mean'}
).loc[1].round(0))
df[df['Date'].isin(['2023-04-22', '2023-04-23', '2024-04-10', '2024-04-11'])]
```

```
Average Sales on Holiday
GDC_sales      512.0
Tapos_sales     365.0
Name: 1, dtype: float64
```

	Date	Holiday	GDC_sales	Tapos_sales
111	2023-04-22	1	512.0	365.0
112	2023-04-23	1	512.0	365.0
465	2024-04-10	1	512.0	365.0
466	2024-04-11	1	512.0	365.0

Gambar 4.5 Kode dan Hasil Penanganan *Missing Values*

4.2.2 Feature Engineering

Pada penelitian ini dilakukan penambahan beberapa fitur atau kolom baru yang diekstraksi dari data tanggal penjualan harian. Proses ini dilakukan untuk meningkatkan kualitas representasi data dan performa model *machine learning*. Kolom baru tersebut adalah '*Dayofweek*', '*Month*', dan '*Dayofmonth*' yang dapat dilihat pada Gambar 4.6.

```
df['Dayofweek'] = df['Date'].dt.dayofweek
df['Month'] = df['Date'].dt.month
df['Dayofmonth'] = df['Date'].dt.day
df
```

	Date	Holiday	GDC_sales	Tapos_sales	Dayofweek	Month	Dayofmonth
0	2023-01-01	1	583	488	6	1	1
1	2023-01-02	0	539	378	0	1	2
2	2023-01-03	0	433	343	1	1	3
3	2023-01-04	0	457	292	2	1	4
4	2023-01-05	0	369	294	3	1	5
...
542	2024-06-26	0	485	259	2	6	26
543	2024-06-27	1	393	342	3	6	27
544	2024-06-28	0	567	350	4	6	28
545	2024-06-29	1	504	390	5	6	29
546	2024-06-30	1	518	353	6	6	30

Gambar 4.6 Kode dan Hasil *Feature Engineering*

Kolom '*Month*' menunjukkan nama bulan dari kolom '*Date*'. Bulan Januari ditampilkan dalam bentuk angka 1, Februari dengan angka 2, hingga Desember dengan angka 12. Untuk kolom '*Dayofmonth*' merupakan tanggal dari kolom '*Date*'. Kolom ini dibuat dengan tujuan membaca pola penjualan di setiap bulannya. Kolom '*Dayofweek*' berisi hari dari tanggal pada kolom '*Date*', hari Senin ditunjukkan dengan angka 0, Selasa dengan angka 1, dan seterusnya hingga Minggu dengan angka 6. Kolom ini dibuat dengan tujuan melihat pola penjualan berdasarkan hari di setiap minggunya. Sedangkan kolom '*Dayofmonth*' merupakan tanggal di setiap bulannya mulai dari tanggal 1 hingga 31.

4.3 Data Transformation (Transformasi Data)

Pada tahapan ini dilakukan transformasi data yaitu perubahan kolom tanggal menjadi *index*. Untuk peramalan penjualan menggunakan algoritma XGBoost, variabel tanggal penjualan perlu dijadikan *index* kolom. Gambar 4.7 menunjukkan data penjualan setelah dilakukan transformasi pada kolom ‘Date’ yang diubah menjadi *index*.

```
df.set_index('Date', inplace=True)
df
```

	Holiday	GDC_sales	Tapos_sales	Dayofweek	Month	Dayofmonth
Date						
2023-01-01	1	583	488	6	1	1
2023-01-02	0	539	378	0	1	2
2023-01-03	0	433	343	1	1	3
2023-01-04	0	457	292	2	1	4
2023-01-05	0	369	294	3	1	5
...
2024-06-26	0	485	259	2	6	26
2024-06-27	1	393	342	3	6	27
2024-06-28	0	567	350	4	6	28
2024-06-29	1	504	390	5	6	29
2024-06-30	1	518	353	6	6	30

Gambar 4.7 Perubahan Kolom ‘Date’ menjadi *index*

4.4 Train-test Split (Pembagian Data Training dan Data Testing)

Pada tahapan ini, dilakukan proses pembagian data untuk melatih (*training*) dan menguji (*testing*) model dengan rasio 80:20, di mana 80% dari keseluruhan data digunakan untuk melatih model agar dapat mengenali pola dan hubungan antar variabel, sementara 20% sisanya disisihkan untuk pengujian (Gambar 4.8).

```
[ ] # GDC Sales
train_size = int(len(df) * 0.8)
train, test = df[:train_size], df[train_size:]

X_train = train.drop('GDC_sales', axis=1)
y_train = train['GDC_sales']
X_test = test.drop('GDC_sales', axis=1)
y_test = test['GDC_sales']

[ ] # Tapos Sales
train_size = int(len(df) * 0.8)
train, test = df[:train_size], df[train_size:]

X_train = train.drop('Tapos_sales', axis=1)
y_train = train['Tapos_sales']
X_test = test.drop('Tapos_sales', axis=1)
y_test = test['Tapos_sales']
```

Gambar 4.8 Pembagian Data *Training* dan Data *Testing*

4.5 Data Mining (Pemilihan dan Ekstraksi)

Setelah dilakukan pembagian data, data *training* kemudian digunakan untuk melatih algoritma XGBoost. Pada penelitian ini, digunakan *library* XGBoost yang sudah tersedia. Langkah yang dilakukan adalah instalasi dan *import library* XGBoost agar bisa digunakan untuk pemodelan peramalan penjualan (Gambar 4.9).

```
[2] | pip install xgboost
    | import xgboost as xgb

Requirement already satisfied: xgboost in /usr/local/lib/python3.10/dist-packages (2.1.1)
Requirement already satisfied: numpy in /usr/local/lib/python3.10/dist-packages (from xgboost) (1.26.4)
Requirement already satisfied: nvidia-nccl-cu12 in /usr/local/lib/python3.10/dist-packages (from xgboost) (2.22.3)
Requirement already satisfied: scipy in /usr/local/lib/python3.10/dist-packages (from xgboost) (1.13.1)
```


Gambar 4.9 Instalasi *Library* XGBoost

Langkah selanjutnya adalah evaluasi data *testing* menggunakan RMSE dan MAPE. Langkah selanjutnya adalah pengujian berulang dengan *cross-validation* untuk menghindari *overfitting*. *Cross-validation* dilakukan menggunakan *library* *cross_val_score* dari *sklearn.model_selection*. Untuk mempermudah proses pengembangan model, tahapan *data mining* untuk data penjualan outlet D'besto

GDC dan D'besto Tapos dilakukan secara terpisah.

4.5.1 Peramalan Penjualan D'besto GDC

Hasil dari proses pembagian data *training* dan *testing* serta evaluasi performa dari algoritma XGBoost dalam melakukan prediksi penjualan pada outlet D'besto GDC dapat dilihat pada Gambar 4.10.



Gambar 4.10 Kode dan Hasil *Data Mining* D'besto GDC

Berdasarkan Gambar 4.10, performa algoritma XGBoost dalam memprediksi penjualan dapat dikatakan baik. Untuk memberikan penjelasan lebih lanjut, dilakukan pengukuran kinerja algoritma ini dengan menghitung skor RMSE dan MAPE (Gambar 4.11).

```
rmse = mean_squared_error(y_test, y_pred, squared=False).round(2)
mape = mean_absolute_percentage_error(y_test, y_pred).round(4)
print("RMSE:", rmse)
print("MAPE:", mape)
```

```
RMSE: 85.17
MAPE: 0.1595
```

Gambar 4.11 Kode dan Hasil RMSE dan MAPE Peramalan Penjualan D'besto GDC

Hasil dari evaluasi performa algoritma XGBoost dalam melakukan peramalan penjualan pada D'besto GDC tergolong baik. Hal ini ditunjukkan dari angka RMSE sebesar 85.17 dan MAPE sebesar 16% (Gambar 4.9). Namun, untuk menghindari kondisi *overfitting*, hasil ini masih perlu ditinjau ulang yaitu dengan melakukan *cross-validation* (Gambar 4.12).

```
from sklearn.model_selection import cross_val_score
# Perform cross-validation with RMSE
rmse_scores = cross_val_score(model, X_train, y_train, cv=5,
                              scoring='neg_mean_squared_error')
rmse_scores = np.sqrt(-rmse_scores)

# Calculate average RMSE
avg_rmse = np.mean(rmse_scores)

# Perform cross-validation with MAPE
mape_scores = cross_val_score(model, X_train, y_train, cv=5,
                              scoring='neg_mean_absolute_percentage_error')

# Calculate average MAPE
avg_mape = np.mean(mape_scores)
```

Gambar 4.12 Kode *Cross-validation* Peramalan Penjualan D'besto GDC

Pada penelitian ini dilakukan *cross-validation* yaitu dengan membagi data sebanyak 5 (lima) *fold* atau lipatan. Model *machine learning* dilatih dan diuji pada setiap lipatan sehingga menghasilkan skor RMSE dan MAPE yang berbeda-beda pula. Hasil dari setiap pengujian dapat dilihat pada Tabel 4.3.

Tabel 4.3 Hasil *Cross-validation* Peramalan Penjualan D'besto GDC

<i>Cross-validation</i>	RMSE	MAPE
<i>Fold 1</i>	56,94	10%
<i>Fold 2</i>	88,08	13,1%


<i>Fold 3</i>	66,01	9,7%
<i>Fold 4</i>	50,13	9%
<i>Fold 5</i>	48,09	9%
Rata-rata	61,89	10,2%

Meskipun skor RMSE dan MAPE mengalami penurunan jika dibandingkan dengan pengujian tanpa *cross-validation*, skor ini masih tergolong baik. Skor rata-rata dari setiap pengujian mencapai angka 61,89 untuk RMSE dan 10,2% untuk MAPE. Hasil dari *cross-validation* yang mengalami penurunan tingkat *error* menunjukkan bahwa model ini tidak *overfitting* dan tidak memerlukan proses *hyperparameter tuning*. Karena hasil dari performa algoritma XGBoost sudah tergolong baik, maka langkah selanjutnya yang dilakukan adalah melakukan peramalan penjualan harian untuk periode Juli–Desember 2024 (Gambar 4.13).

```
train, test = df[df['Date'] < '2024-07-01'], df[df['Date'] >= '2024-07-01']
train.set_index('Date', inplace=True)
test.set_index('Date', inplace=True)
```

Gambar 4.13 Pembagian Data untuk Peramalan Penjualan

Pada langkah ini digunakan data penjualan pada periode Januari 2023–Juni 2024 sebagai data *training* untuk memprediksi penjualan pada periode Juli–Desember 2024. Langkah selanjutnya adalah memulai pemodelan *machine learning* seperti yang dapat dilihat pada Gambar 4.14.



Gambar 4.14 Hasil Peramalan Penjualan D’besto GDC Periode Juli–Desember 2024

Gambar 4.14 menunjukkan hasil peramalan penjualan harian pada outlet D’besto GDC untuk periode Juli–Desember 2024. Data yang lebih lengkap mengenai peramalan penjualan setiap harinya dapat dilihat pada Tabel 4.4.

Tabel 4.4 Hasil Peramalan Penjualan D’besto GDC
Periode Juli–Desember 2024

Peramalan Penjualan Harian D’besto GDC Periode Juli–Desember 2024						
Tanggal	Bulan					
	Juli	Agustus	September	Oktober	November	Desember
1	415	408	490	386	425	449
2	415	460	389	386	460	391
3	408	491	385	385	491	406
4	415	453	384	427	395	418
5	474	415	395	463	407	420
6	473	412	433	518	403	455
7	505	402	469	392	403	470
8	409	405	522	400	430	552
9	409	445	401	401	458	414
10	425	481	402	402	546	429
11	416	520	392	401	404	419
12	484	420	376	398	404	413
13	483	421	436	584	423	442
14	526	424	489	419	419	470

15	426	424	537	413	442	591
16	438	442	406	409	426	395
17	439	446	407	410	586	405
18	402	454	402	438	424	422
19	439	409	402	429	424	416
20	409	404	419	493	424	429
21	448	420	432	432	432	456
22	421	435	501	437	443	481
23	411	441	403	406	421	406
24	402	447	396	399	455	407
25	407	462	394	418	407	522
26	483	430	416	456	418	525
27	471	421	428	479	402	418
28	530	411	436	404	401	463
29	417	424	476	382	401	503
30	410	457	395	398	446	394
31	404	479		414		536

4.5.2 Peramalan Penjualan D'besto Tapos

Langkah yang sama juga dilakukan terhadap data penjualan outlet D'besto Tapos. Hasil dari proses pembagian data serta evaluasi performa dari algoritma XGBoost dalam melakukan prediksi penjualan pada outlet D'besto Tapos dapat dilihat pada Gambar 4.15.



Gambar 4.15 Kode dan Hasil *Data Mining* D'besto Tapos

Berdasarkan Gambar 4.15, performa algoritma XGBoost dalam memprediksi penjualan tergolong baik karena dapat membaca pola yang ada pada data. Untuk memberikan penjelasan lebih lanjut, dilakukan pengukuran performa algoritma dengan menghitung skor RMSE dan MAPE (Gambar 4.16).

```

rmse = mean_squared_error(y_test, y_pred, squared=False).round(2)
mape = mean_absolute_percentage_error(y_test, y_pred).round(4)
print("RMSE:", rmse)
print("MAPE:", mape)

```

RMSE: 77.56
MAPE: 0.1687

Gambar 4.16 Kode dan Hasil RMSE dan MAPE Peramalan Penjualan D'besto Tapos

Hasil dari evaluasi performa algoritma XGBoost dalam melakukan peramalan penjualan pada D'besto Tapos tergolong baik. Hal ini ditunjukkan dari angka RMSE sebesar 77,56 dan MAPE sebesar 16,9% (Gambar 4.16). Namun, hasil ini masih perlu ditinjau ulang yaitu dengan melakukan *cross-validation*.


Tahapan ini dilakukan seperti yang tertera pada Gambar 4.10. Hasil dari setiap pengujian dapat dilihat pada Tabel 4.5.

Tabel 4.5 Hasil *Cross-validation* Peramalan Penjualan D’besto Tapos

<i>Cross-validation</i>	RMSE	MAPE
<i>Fold 1</i>	52,26	16,3%
<i>Fold 2</i>	68,52	18,1%
<i>Fold 3</i>	68,03	13,7%
<i>Fold 4</i>	44,34	9,8%
<i>Fold 5</i>	47,82	12,6%
Rata-rata	56,2	14,1%

Skor RMSE dan MAPE pada data D’besto Tapos juga mengalami penurunan jika dibandingkan dengan pengujian tanpa *cross-validation*. Namun, rata-rata dari skor untuk setiap pengujian masih tergolong baik, yaitu di angka 56,2 untuk RMSE dan 14,1% untuk MAPE. Hasil dari *cross-validation* yang mengalami penurunan tingkat *error* menunjukkan bahwa model ini tidak *overfitting* dan tidak memerlukan proses *hyperparameter tuning*. Karena hasil dari performa algoritma XGBoost sudah tergolong baik, maka langkah selanjutnya yang dilakukan adalah melakukan peramalan penjualan harian untuk periode Juli–Desember 2024.

Pada langkah ini digunakan data penjualan pada periode Januari 2023–Juni 2024 sebagai data *training* untuk memprediksi penjualan pada periode Juli–Desember 2024. Kemudian, dilakukan pemodelan *machine learning* yang dapat dilihat pada Gambar 4.17.



Gambar 4.17 Hasil Peramalan Penjualan D'besto Tapos Periode Juli–Desember 2024

Gambar 4.17 menunjukkan hasil peramalan penjualan harian pada outlet D'besto Tapos untuk periode Juli–Desember 2024. Untuk data lebih detailnya dapat dilihat pada Tabel 4.6.

Tabel 4.6 Hasil Peramalan Penjualan D'besto Tapos
Periode Juli–Desember 2024

Peramalan Penjualan Harian D'besto Tapos Periode Juli–Desember 2024						
Tanggal	Bulan					
	Juli	Agustus	September	Oktober	November	Desember
1	335	327	441	303	397	431
2	333	389	304	304	378	342
3	335	412	306	306	503	312
4	306	416	296	358	299	312
5	360	314	313	417	291	290
6	376	316	403	483	293	365
7	446	300	431	299	284	388
8	313	327	488	311	359	404
9	342	390	332	332	381	349
10	363	437	342	342	484	357
11	339	459	308	393	331	395
12	361	332	292	422	313	342
13	387	360	400	515	319	396
14	461	359	435	321	310	391

15	330	374	505	315	375	396
16	307	358	309	310	379	312
17	290	414	319	320	480	334
18	342	431	325	392	325	335
19	296	343	333	419	333	352
20	332	343	352	429	328	402
21	388	343	407	329	328	386
22	303	343	421	329	409	392
23	299	387	324	325	368	343
24	296	417	321	323	431	336
25	284	417	322	390	312	318
26	363	352	337	431	337	327
27	375	357	399	461	342	415
28	433	343	429	331	330	387
29	301	342	458	305	355	429
30	306	352	319	321	375	332
31	292	446		329		332

4.6 *Evaluation/Interpretation* (Evaluasi/Interpretasi)

Pada tahapan ini dilakukan pengecekan *feature importance* dengan tujuan mengidentifikasi dan memahami kontribusi setiap fitur (variabel input) terhadap prediksi model. Gambar 4.18 menunjukkan langkah pengecekan *feature importance* pada data penjualan di kedua outlet. Hasil pengecekan pada kedua outlet dapat dilihat pada Gambar 4.19 dan Gambar 4.20.

```

import pandas as pd
import matplotlib.pyplot as plt
importances = model.feature_importances_
columns = X_train.columns

importance_df = pd.DataFrame({
    'feature': columns,
    'importance': importances
})


importance_df = importance_df.sort_values(by='importance', ascending=False)


importance_df['importance_percentage'] = 100.0 * importance_df['importance']
                                     / importance_df['importance'].sum()

print(importance_df)

plt.figure(figsize=(10, 6))
sns.barplot(x='importance_percentage', y='feature', data=importance_df)
plt.title('Feature Importance (%)')
plt.show()

```

Gambar 4.18 Kode Pengecekan *Feature Importance*Gambar 4.19 *Feature Importance* terhadap Data Penjualan D'besto GDC




Gambar 4.20 *Feature Importance* terhadap Data Penjualan D'besto Tapos

Gambar 4.19 menunjukkan bahwa variabel '*Dayofweek*' memiliki tingkat kepentingan paling tinggi dalam melakukan peramalan penjualan untuk outlet D'besto GDC, yaitu di angka 37,8%. Lalu disusul dengan variabel '*Holiday*' yang mencapai angka 35,5%. *Feature Importance* terhadap data penjualan D'besto Tapos pada Gambar 4.20 juga menunjukkan hasil yang serupa, dimana variabel '*Dayofweek*' dan '*Holiday*' menjadi dua variabel terpenting yang mempengaruhi volume penjualan. Pada outlet Tapos, variabel '*Dayofweek*' memiliki angka kepentingan sebesar 51,2% dan variabel '*Holiday*' memiliki angka kepentingan sebesar 27,2%. Hal ini menandakan bahwa volume penjualan berkaitan erat dengan hari dalam setiap pekannya dan hari libur nasional.


Langkah selanjutnya adalah analisis lebih lanjut mengenai kedua variabel tersebut. Gambar 4.21 menunjukkan adanya pola penjualan mingguan yang dimiliki

oleh data penjualan dari kedua outlet ini. Dari gambar tersebut dapat disimpulkan bahwa hari Jumat, Sabtu, dan Minggu memiliki angka penjualan yang lebih tinggi dibandingkan dengan hari lainnya. Hal ini menunjukkan bahwa variabel ‘*Dayofweek*’ memiliki pengaruh yang cukup kuat terhadap data penjualan harian, baik di outlet D’besto GDC, maupun D’besto Tapos.




Gambar 4.21 Rata-Rata Penjualan Harian Berdasarkan Hari

Gambar 4.22 menunjukkan bahwa perbandingan volume penjualan D’besto GDC pada hari libur dan bukan hari libur terlihat cukup signifikan. Hal ini ditunjukkan dari puncak distribusi data penjualan pada hari libur yang lebih tinggi dibandingkan dengan yang bukan hari libur. Rata-rata dari penjualan pada hari libur mencapai 512 per hari nya. Sedangkan rata-rata penjualan harian pada bukan hari libur hanya di angka 436. Selisih yang cukup besar ini menunjukkan variabel ‘*Holiday*’ memiliki korelasi yang kuat dengan volume penjualan di outlet D’besto GDC.



Gambar 4.22 Perbandingan Penjualan pada Hari Libur dan Bukan Libur di D’besto GDC

Gambar 4.23 menunjukkan perbandingan volume penjualan D’besto Tapos pada hari libur dan tidak. Rata-rata dari penjualan pada hari libur mencapai 365 produk per hari nya. Sedangkan rata-rata penjualan harian pada bukan hari libur adalah 321 produk per harinya. Perbedaan volume penjualan pada hari libur juga terlihat dari puncak distribusi data penjualan pada hari libur yang lebih tinggi dibandingkan dengan yang bukan hari libur. Selisih ini menunjukkan bahwa variabel ‘*Holiday*’ memiliki korelasi yang cukup kuat dengan volume penjualan di outlet D’besto Tapos.



Gambar 4.23 Perbandingan Penjualan pada Hari Libur dan Bukan Libur di D'besto Tapos

4.7 Perhitungan *Safety Stock*

Pada tahap ini dilakukan perhitungan *safety stock* dengan bantuan *tools* Microsoft Excel. Penggunaan rumus `=AVERAGE` dan `=STDEV` pada Excel digunakan untuk mencari rata-rata dan standar deviasi dari prediksi penjualan kedua outlet. Perhitungan ini dilakukan berdasarkan hasil peramalan penjualan yang telah dilakukan pada tahap sebelumnya. Diketahui bahwa standar deviasi dari prediksi penjualan periode Juli–Desember 2024 adalah seperti yang tertera di Tabel 4.7.

Tabel 4.7 Rata-Rata dan Standar Deviasi Prediksi Penjualan Harian

Outlet	Rata-rata	Standar Deviasi
D'besto GDC	435,35	42,15
D'besto Tapos	359,67	51,89

Pada penelitian ini digunakan angka 95% untuk *service level* yaitu sebesar 1,64 pada Tabel Z. Diketahui bahwa proses pemesanan stok hingga stok sampai di

outlet, atau yang biasa disebut dengan *lead time*, dari kedua outlet ini adalah 2 hari. Setelah standar deviasi, *service level*, dan *lead time* sudah diketahui maka perhitungan *safety stock* dapat dilakukan.

Perhitungan *safety stock* pada outlet D'besto GDC dengan rumus (2.4):

$$SS = 42,15 \times 1,64 \times \sqrt{2} = 97,75$$

Setelah dilakukan perhitungan tersebut didapatkan hasil *safety stock* untuk produk *fried chicken* pada outlet D'besto GDC adalah sebesar 97,75 produk atau dibulatkan menjadi 98 produk. Selanjutnya perhitungan yang sama dilakukan terhadap data dari outlet D'besto Tapos.

Perhitungan *safety stock* pada outlet D'besto Tapos dengan rumus (2.4):

$$SS = 51,89 \times 1,64 \times \sqrt{2} = 120,34$$

Perhitungan tersebut menunjukkan hasil *safety stock* untuk produk *fried chicken* pada outlet D'besto Tapos adalah sebesar 120,34 produk atau dibulatkan menjadi 120 produk. Angka *safety stock* dari kedua outlet akan berguna untuk perhitungan *reorder point* yang akan dilakukan di tahap berikutnya.

4.8 Perhitungan *Reorder Point*

Setelah perhitungan *safety stock* dilakukan, langkah selanjutnya adalah dilakukan perhitungan dengan bantuan *tools* Microsoft Excel untuk mengetahui titik *reorder point* untuk produk *fried chicken* di kedua outlet. Untuk perhitungan *reorder point* diperlukan rata-rata dari prediksi penjualan pada kedua outlet. Diketahui rata-rata yang dimiliki D'besto GDC adalah sebesar 435,35 atau

dibulatkan menjadi 435. Dan rata-rata yang dimiliki D'besto Tapos adalah sebesar 359,67 atau dibulatkan menjadi 360 (Tabel 4.5).

Perhitungan *reorder point* untuk D'besto GDC dengan rumus (2.5):

$$ROP = (435 \times 2) + 98 = 968$$

Berdasarkan perhitungan tersebut, didapatkan hasil bahwa titik *reorder point* yang dimiliki D'besto GDC adalah sebesar 968 produk. Angka ini menunjukkan tingkat stok minimum dimana pemesanan ulang perlu dilakukan kembali. Selanjutnya dilakukan perhitungan yang sama terhadap data prediksi penjualan D'besto Tapos.

Perhitungan *reorder point* untuk D'besto Tapos dengan rumus (2.5):

$$ROP = (360 \times 2) + 120 = 840$$

Berdasarkan perhitungan tersebut, didapatkan hasil bahwa titik *reorder point* yang dimiliki D'besto Tapos adalah sebesar 840 produk. Angka ini menunjukkan tingkat stok minimum dimana pemesanan ulang perlu dilakukan kembali. Hasil perhitungan *safety stock* dan *reorder point* pada D'besto GDC dan Tapos dapat dilihat pada Tabel 4.8.

Tabel 4.8 Hasil Perhitungan *Safety Stock* dan *Reorder Point*

Outlet	<i>Safety Stock</i>	<i>Reorder Point</i>
D'besto GDC	98	968
D'besto Tapos	120	840

4.9 Rekomendasi

Berdasarkan hasil penelitian yang telah dipaparkan pada bagian sebelumnya, berikut adalah beberapa rekomendasi yang dapat diterapkan oleh D'besto GDC dan

D'besto Tapos:

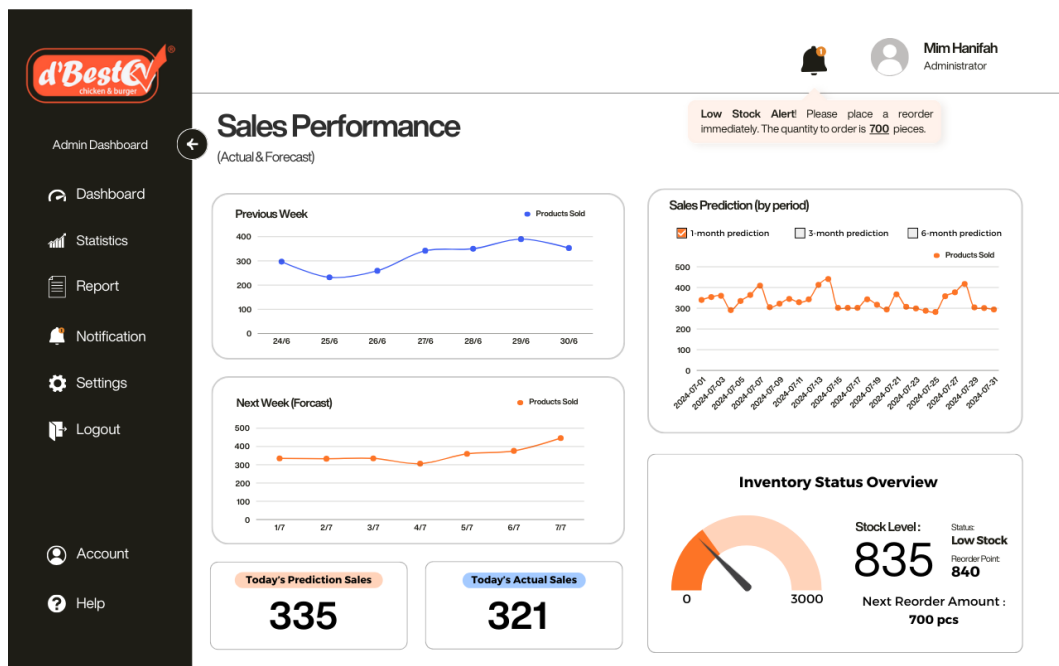
4.9.1 Implementasi Sistem Peramalan Penjualan

Untuk mengimplementasikan model *machine learning* XGBoost yang telah dilatih pada bagian sebelumnya, perusahaan perlu menerapkan beberapa langkah berikut:

- a. Menentukan tempat untuk menempatkan model XGBoost yang sudah dilatih, seperti *cloud* atau server internal perusahaan.
- b. Membangun API yang memungkinkan sistem informasi perusahaan untuk berinteraksi dengan model. API ini akan menerima input data penjualan baru dan mengembalikan hasil prediksi.
- c. Mengintegrasikan API dengan sistem operasional perusahaan, sehingga data penjualan terbaru dapat dikirim ke model dan prediksi dapat diterima secara *real-time*.
- d. Memantau performa model di lingkungan produksi, pastikan akurasi tetap stabil seiring waktu.

4.9.2 Visualisasi Dashboard Peramalan Penjualan


Berdasarkan hasil penelitian, peneliti membuat usulan mengenai tampilan *interface* untuk halaman *dashboard* pada sistem peramalan penjualan yang dapat digunakan untuk memantau penjualan, prediksi penjualan, ketersediaan stok, serta notifikasi pemesanan ulang stok (Gambar 4.24).

Gambar 4.24 Tampilan *Dashboard*

Berikut penjelasan lebih detail terkait rekomendasi tampilan *dashboard* tersebut.

a. **Prediksi Penjualan Minggu Depan**


Tampilan ini menampilkan data penjualan harian selama 7 hari terakhir. Data yang ditampilkan meliputi jumlah unit produk yang terjual per hari, sehingga memungkinkan pengguna untuk melihat pola penjualan aktual dalam periode seminggu. Informasi ini penting untuk mengevaluasi performa penjualan harian dan mengidentifikasi tren penjualan jangka pendek (Gambar 4.25).



Gambar 4.25 Tampilan Grafik Penjualan Satu Minggu Terakhir

b. Penjualan Satu Minggu Terakhir

Tampilan ini menunjukkan prediksi penjualan untuk 7 hari ke depan berdasarkan model XGBoost yang digunakan. Prediksi ini disajikan dalam bentuk grafik atau tabel, dengan estimasi jumlah unit yang akan terjual per hari. Tampilan ini membantu manajemen dalam perencanaan strategi, seperti mempersiapkan stok dan menentukan langkah-langkah promosi berdasarkan data prediksi (Gambar 4.26).



Gambar 4.26 Tampilan Grafik Prediksi Penjualan Seminggu ke Depan

c. Prediksi dan Aktualisasi Penjualan Hari Ini

Tampilan prediksi penjualan hari ini berfokus pada estimasi penjualan untuk hari ini, memberikan gambaran tentang berapa banyak produk yang diperkirakan

akan terjual. Informasi ini bermanfaat untuk menentukan kebutuhan stok dan mengatur strategi operasional, misalnya berapa banyak produk yang perlu disiapkan untuk memenuhi permintaan.


Sedangkan tampilan aktualisasi penjualan hari ini memperlihatkan penjualan yang telah terjadi sepanjang hari ini. Informasi ini memungkinkan pengguna untuk membandingkan penjualan aktual dengan prediksi yang sebelumnya disajikan, serta untuk mengevaluasi kinerja penjualan harian (Gambar 4.27).



Gambar 4.27 Tampilan Prediksi dan Aktualisasi Penjualan Hari Ini

d. **Prediksi Penjualan Berdasarkan Periode**


Fitur ini memungkinkan pengguna untuk memfilter prediksi penjualan berdasarkan periode waktu: 1 bulan, 3 bulan, atau 6 bulan ke depan. Dengan demikian, manajemen dapat melihat proyeksi penjualan dalam jangka pendek, menengah, dan panjang. Fitur ini sangat berguna untuk perencanaan stok, strategi promosi, dan alokasi sumber daya jangka panjang (Gambar 4.28).



Gambar 4.28 Tampilan Prediksi Penjualan Berdasarkan Periode

e. Ringkasan Status Persediaan Bahan Baku

Tampilan ini menyajikan informasi penting mengenai status persediaan produk di outlet. Tampilan ini juga disertai dengan jumlah stok saat ini, perhitungan *reorder point* atau titik di mana stok mencapai batas minimal dan perlu dilakukan pemesanan ulang, serta jumlah produk yang harus dipesan ulang untuk memenuhi kebutuhan di periode berikutnya, berdasarkan prediksi penjualan (Gambar 4.29).




Gambar 4.29 Tampilan Ringkasan Status Stok Bahan Baku

f. Notifikasi Pemesanan Ulang

Fitur ini memberikan notifikasi otomatis kepada manajemen ketika stok

mencapai titik *reorder*. Notifikasi ini memastikan perusahaan tidak kehabisan stok secara tiba-tiba dan bisa memesan ulang tepat waktu untuk menjaga kelancaran operasional (Gambar 4.30).



Gambar 4.30 Tampilan Notifikasi Pemesanan Ulang

4.9.3 Pengendalian Persediaan Bahan Baku

Perusahaan perlu memanfaatkan hasil prediksi penjualan dan perhitungan *safety stock* serta *reorder point* untuk pengendalian persediaan bahan baku. Hasil prediksi penjualan dapat digunakan sebagai acuan untuk menentukan jumlah produksi setiap harinya serta jumlah stok bahan baku yang perlu dipesan untuk periode berikutnya. Perusahaan perlu memastikan ketersediaan jumlah *safety stock* di outlet untuk mengantisipasi fluktuasi permintaan yang tidak terduga. Selain *safety stock*, perusahaan juga perlu melakukan perhitungan jumlah stok bahan baku secara rutin dan melakukan pemesanan ulang jika jumlah persediaan sudah mencapai titik *reorder point* di masing-masing outlet.

4.9.4 Strategi Promosi

Mengingat bahwa volume penjualan mengalami peningkatan yang signifikan pada hari-hari tertentu, perusahaan sebaiknya merancang strategi promosi pada waktu-waktu tersebut. Misalnya dengan melakukan peluncuran produk baru di hari libur, *weekend*, dan Hari Jumat. Selain itu, perusahaan juga

perlu memperhatikan hari-hari dimana penjualan tidak mengalami peningkatan. Perusahaan sebaiknya menerapkan strategi promosi pada hari Senin–Kamis berupa diskon ataupun promo.

4.9.5 Peningkatan Layanan dan Kualitas

Dalam melakukan peningkatan layanan dan kualitas, perusahaan perlu memperhatikan dan melakukan analisis terhadap umpan balik dari pelanggan secara rutin untuk mengidentifikasi area yang perlu diperbaiki dan untuk memahami kebutuhan serta preferensi pelanggan. Selain itu, perusahaan juga perlu mengantisipasi volume penjualan yang fluktuatif. Meningkatnya volume penjualan juga perlu diiringi dengan kesiapan karyawan dalam memenuhi permintaan pelanggan. Sehingga perusahaan perlu melakukan pelatihan dan penyuluhan berkelanjutan bagi karyawan dalam menghadapi periode dengan volume penjualan yang tinggi. Perusahaan bisa menambahkan jumlah karyawan yang bertugas pada waktu tertentu dimana penjualan cenderung meningkat. Selain untuk membantu menyediakan produk, penambahan karyawan ini juga diperlukan untuk terus memastikan bahwa outlet tetap bersih di area dapur, kasir, dan area makan atau *dine in*.



BAB 5

PENUTUP

5.1 Kesimpulan

Berdasarkan hasil penelitian yang telah dipaparkan pada bab sebelumnya, maka didapatkan kesimpulan sebagai berikut:

- a. Berdasarkan hasil peramalan penjualan dengan *library* XGBoost terhadap penjualan *fried chicken* pada D'besto GDC didapatkan hasil akhir pengujian yaitu RMSE sebesar 61,89 dan MAPE sebesar 10,2% dengan rata-rata prediksi penjualan harian periode Juli–Desember 2024 adalah sebesar 435 produk per harinya. Sedangkan untuk D'besto Tapos didapatkan RMSE sebesar 56,2 dan MAPE sebesar 14,1% dengan rata-rata prediksi penjualan harian periode Juli–Desember 2024 adalah sebesar 360 per harinya.
- b. Berdasarkan pengukuran *feature importance*, variabel *holiday* (hari libur nasional) dan *days of week* (hari dalam seminggu) memiliki pengaruh signifikan terhadap volume penjualan di kedua outlet. Variabel *holiday* memberikan kontribusi sebesar 35,5% di D'besto GDC dan 27,2% di D'besto Tapos. Sedangkan variabel *days of week* memberikan kontribusi sebesar 37,8% di D'besto GDC dan 51,2% di D'besto Tapos.
- c. Dari perhitungan *safety stock* dan *reorder point*, didapatkan hasil untuk angka *safety stock* adalah sebesar 98 pada D'besto GDC dan 120 pada D'besto Tapos. Sedangkan untuk *reorder point* didapatkan angka 968 pada D'besto GDC dan 840 pada D'besto Tapos.

5.2 Saran

Berdasarkan penelitian yang telah dilakukan, peneliti memberikan saran terhadap penelitian selanjutnya, yaitu sebagai berikut:

- a. Melakukan penelitian lanjutan dengan menggunakan periode data historis penjualan yang lebih lama (di atas 18 bulan) untuk meningkatkan performa model hingga termasuk ke dalam kategori peramalan yang sangat baik.
- b. Melakukan penelitian lebih lanjut mengenai peramalan penjualan dengan menggunakan algoritma *machine learning* selain XGBoost untuk membandingkan performa algoritma dan tingkat kesalahannya.
- c. Perlu dilakukan penelitian lebih lanjut dengan mempertimbangkan kriteria lain seperti promo, diskon, dan kriteria lainnya yang memiliki pengaruh pada volume penjualan untuk menjadi variabel tambahan dalam pengembangan model peramalan penjualan.

DAFTAR PUSTAKA

- Aghnani, K., & Perdana, T. (2019). Memahami Manajemen Persediaan Pada Perusahaan Agroindustri Menggunakan Alat Berpikir Sistem. *Jurnal Ilmiah Mahasiswa AGROINFO GALUH*, 6(1), 259–272.
<http://dx.doi.org/10.25157/jimag.v6i1.1950>
- Allied. (2020, December 25). *Fast Food Market*.
<https://www.alliedmarketresearch.com/fast-food-market#:~:text=The%20fast%20food%20market%20size,quick%20to%20prepare%20and%20serve>.
- Annur, C. M. (2023, February 16). *Perempuan Lebih Sering Konsumsi Makanan Cepat Saji Ketimbang Laki-laki*. Databooks.
<https://databoks.katadata.co.id/datapublish/2023/02/16/perempuan-lebih-sering-konsumsi-makanan-cepat-saji-ketimbang-laki-laki>
- Asia, M. I. M. (2024, March 24). *Melek Isu “Food Loss” dan “Food Waste.”* Kompas.Com.
<https://lestari.kompas.com/read/2024/02/15/163303686/melek-isu-food-loss-dan-food-waste?page=all>
- Coherent. (2023, July 19). *Fast Food Market Analyst*.
<https://www.coherentmarketinsights.com/market-insight/fast-food-market-5896#:~:text=The%20global%20fast%20food%20market,driving%20fast%20food%20market%20growth>.

- Dairu, X., & Shilong, Z. (2021). Machine Learning Model for Sales Forecasting by Using XGBoost. *2021 IEEE International Conference on Consumer Electronics and Computer Engineering, ICCECE 2021*, 2(1), 480–483. <https://doi.org/10.1109/ICCECE51280.2021.9342304>
- Damanik, F., Meilano, R., & Tanto. (2019). Pengembangan Sistem Informasi Persediaan Barang dengan Metode Waterfall. *Jurnal Elektronika, Listrik, Dan Teknologi Informasi Terapan*, 2(1), 30–34. <https://doi.org/10.37338/e.v2i2.153>
- Doresdiana, H., Sugiyono, & Saluy, A. B. (2021). Spare Parts Demand Forecasting During Covid 19 Pandemic (Automotive Company Case Study). *Dinasti International Journal of Economics, Finance & Accounting*, 2(2), 215–226. <https://doi.org/10.38035/dijefa.v2i2.852>
- Eby, K. (2020, January 26). *The Last Guide to Sales Forecasting You'll Ever Need: How-To Guides and Examples*. Smartsheet.
- Ekankumo, B. (2023). Marketing Mix Elements and Brand Loyalty in the Nigerian Telecommunication Industry. *British Journal of Management and Marketing Studies*, 6(1), 84–96. <https://doi.org/10.52589/bjmms-yxxasljm>
- Fitriyah, S. Z., Dahda, S. S., & Ismiyah, E. (2022). Perencanaan Produksi Pada Produk Pestisida Menggunakan Metode Goal Programming (Studi Kasus: Plant WP Pabrik I PT Petrokimia Kayaku). *JUSTI (Jurnal Sistem Dan Teknik Industri)*, 1(2), 187–204. <http://dx.doi.org/10.30587/justicb.v1i2.3856>
- GVR. (2022, February 22). *Market Analysis Report*. <https://www.grandviewresearch.com/industry-analysis/fast-food-market#:~:text=Report%20Overview,5.0%25%20from%202022%20to%202029>.
- Haq, M. A. S., Alhakim, M. H., & Zuhdan, F. M. (2023). Pengaruh Musim Libur Terhadap Omzet Penjualan Korean Toast Bread di Lokasi Wisata Heha Sky View Yogyakarta Studi Kasus: Sejalan Toast. *Jurnal Inspirasi Smamio (JURNISMIO)*, 1(1), 329–355. <https://ojs.smam10gkb.sch.id/index.php/Jurnismio/article/view/18>
- Hasan, R. (2024). Addressing Seasonality and Trend Detection in Predictive Sales

- Forecasting: A Machine Learning Perspective. *Journal of Business and Management Studies*, 1(1), 100–109. <https://doi.org/10.32996/jbms>
- Heaviside, M., Mulyawan, B., & Sutrisno, T. (2020). Determination of minimum stock on system retail using forecast, economic order quantity and reorder point methods. *IOP Conference Series: Materials Science and Engineering*, 1007(1), 1–6. <https://doi.org/10.1088/1757-899X/1007/1/012180>
- Huo, Z. (2021). Sales Prediction based on Machine Learning. *Proceedings - 2nd International Conference on E-Commerce and Internet Technology, ECIT 2021*, 410–415. <https://doi.org/10.1109/ECIT52743.2021.00093>
- Husein, A. M., Lubis, F. R., & Harahap, M. K. (2019). Analisis Prediktif untuk Keputusan Bisnis: Peramalan Penjualan. *Data Science Indonesia (DSI)*, 1(1), 32–40. <https://doi.org/10.47709/dsi.v1i1.1196>
- KBV. (2021, November 15). *Fast Food Market*. <https://www.kbvresearch.com/fast-food-market/table-of-content/>
- Korstanje, J. (2021). *Advanced forecasting with python*. Apress Media LLC.
- Koufi, N. El, Belangour, A., & Sidiq, M. (2022). Research on Precision Marketing based on Big Data Analysis and Machine Learning: Case Study of Morocco. *IJACSA) International Journal of Advanced Computer Science and Applications*, 13(10), 58–63.
- Kristanti, M., Nugrohowati, N., Harjono, Y., & Fairuz, N. (2024). Faktor-Faktor Yang Mempengaruhi Sikap Remaja Dalam Mengkonsumsi Makanan Cepat Saji. *Jurnal Ilmu Kesehatan Masyarakat*, 13(1), 44–49. <https://doi.org/10.33221/jikm.v13i01.2411>
- Lazzeri, F. (2021). *Machine Learning for Time Series Forecasting with Python* (1st ed.). John Wiley & Sons.
- Massaro, A., Panarese, A., Giannone, D., & Galiano, A. (2021). Augmented Data and XGBoost Improvement for Sales Forecasting in the Large-Scale Retail Sector. *Applied Sciences*, 11(17), 7793–7800. <https://doi.org/10.3390/app11177793>
- Muktamar, A., Iagusnawati, R., Imaulana, M., & Iawal, J. (2023). Pengambilan Keputusan dan Perencanaan Kebijakan. *Journal Of International*

- Multidisciplinary Research*, 1(2), 1125–1135.
<https://journal.banjaresepacific.com/index.php/jimr>
- Muller, J. P., & Massaron, L. (2019). *Python for Data Science for Dummies* (2nd ed.). John Wiley & Sons.
- Nissa, D. A., Supian, S., & Nahar, J. (2023). Inventory Control for MSME Products Using the Q Model with Lost Sales Condition Based on Products Sales Forecasting. *International Journal of Quantitative Research and Modeling*, 4(1), 20–29.
<https://journal.rescollacomm.com/index.php/ijqrm/article/view/417>
- Niu, Y. (2020). Walmart Sales Forecasting using XGBoost algorithm and Feature engineering. *2020 International Conference on Big Data & Artificial Intelligence & Software Engineering (ICBASE)*, 458–461.
<https://doi.org/10.1109/ICBASE51474.2020.00103>
- Nugraha, A. C., & Irawan, M. I. (2023). Komparasi Deteksi Kecurangan pada Data Klaim Asuransi Pelayanan Kesehatan Menggunakan Metode Support Vector Machine (SVM) dan Extreme Gradient Boosting (XGBoost). *Jurnal Sains Dan Seni ITS*, 12(1), A40–A46.
<https://doi.org/10.12962/j23373520.v12i1.107032>
- Panarese, A., Settanni, G., Vitti, V., & Galiano, A. (2022). Developing and Preliminary Testing of a Machine Learning-Based Platform for Sales Forecasting Using a Gradient Boosting Approach. *Applied Sciences (Switzerland)*, 12(1), 1–15. <https://doi.org/10.3390/app122111054>
- Pavlyshenko, B. M. (2019). Machine-learning Models for Sales Time Series Forecasting. *Data*, 4(1), 15–26. <https://doi.org/10.3390/data4010015>
- Presswire, E. (2024, January 9). *Kloud9 Launches Stockout Sentinel to Help Retailers Battle a Growing Problem with Stock-outs*. Fox40. <https://fox40.com/business/press-releases/ein-presswire/680052462/kloud9-launches-stockout-sentinel-to-help-retailers-battle-a-growing-problem-with-stock-outs/>
- Putra, S. A. (2019). Analisa Peramalan Penjualan dan Promosi Penjualan Terhadap Peningkatan Volume Penjualan pada PT. Cakra Anugerah Arta Alumindo

- Medan. *Jurnal Manajemen Dan Akuntansi Medan*, 1(3), 142–160.
- Raizada, S., & Saini, J. R. (2021). Comparative Analysis of Supervised Machine Learning Techniques for Sales Forecasting. *International Journal of Advanced Computer Science and Applications (IJACSA)*, 12(11), 102–110.
- Richard, M. (2019, February 11). *Bisnis Restoran Cepat Saji Berpeluang Tumbuh 15% Tahun Ini*. Bisnis.Com. <https://ekonomi.bisnis.com/read/20190211/12/887488/bisnis-restoran-cepat-saji-berpeluang-tumbuh-15-tahun-ini>
- Ruqoyyah, S., Murni, S., & Linda. (2020). *Kemampuan Pemahaman Konsep Dan Resiliensi Matematika Dengan VBA Microsoft Excel* (G. D. S. Rahayu, Ed.; pp. 14–16). CV. Tre Alea Jacta Pedagogie.
- Santos, J. M. J. (2020). *Reorder Point Definition Through Demand Forecasting To Manage Stock Levels*. (Publication No. 202591760) [Doctoral dissertation, Universidade Do Porto]. Universidade Do Porto Repository. <https://repositorio-aberto.up.pt/handle/10216/132649>
- Silaen, T. A., & Iskandar, Y. A. (2023). Inventory Management with Demand Forecast for Eyeglass Lenses Using The Time Series Method at An Optical Store. *Journal of Emerging Supply Chain, Clean Energy, and Process Engineering*, 2(2), 85–97. <https://doi.org/10.57102/jescee.v2i2.65>
- Stockpedia. (2024). *Number of Years Consecutive Sales Growth*. Stockpedia. <https://www.stockopedia.com/ratios/no.-of-years-consecutive-sales-growth-5062/>
- Straits. (2023, October 13). *Fast Food Market Size, Growth, Trends and Forecast to 2032*. Straits Research. <https://straitsresearch.com/report/fast-food-market/toc>
- Tanamal, R., Nurdiansyah, Y., & Firdaus, F. (2020). Inventory Support System for Retail Shop. *E3S Web of Conferences*, 188(4), 20–27. <https://doi.org/10.1051/e3sconf/202018800020>
- Tawn, R., Browell, J., & Dinwoodie, I. (2020). Missing data in wind farm time series: Properties and effect on forecasts. *Electric Power Systems Research*, 189(1), 378–386. <https://doi.org/10.1016/j.epsr.2020.10664>

- Turgut, Y., & Erdem, M. (2022). Forecasting of Retail Produce Sales Based on XGBoost Algorithm. *Global Joint Conference on Industrial Engineering and Its Application Areas*, 27–43. https://doi.org/10.1007/978-3-030-76724-2_3
- Vieira, R. P. M., Alves, F. R. V., & Catarino, P. M. M. C. (2019). Alternative Views of Some Extensions of The Padovan Sequence with The Google Colab. *Annals. Computer Science Series*, 17(2), 266–273.
- Wahab, D., Anggadini, S. D., Yunanto, R., & Soegoto, D. S. (2023). *Ekosistem Bisnis & Transformasi Digital Perspektif Keberlanjutan Usaha Kecil Kuliner* (1st ed., Vol. 1). CV AA Rizky.
- Wahyuni, A., & Nugroho, P. S. (2022). Hubungan Kebiasaan Olahraga dan Konsumsi Fast Food dengan Kejadian Overweight pada Remaja di SMAN 1 Sangkulirang. *Borneo Studies and Research*, 3(2), 1769–1803.
- Wanti, L. P., Prasetya, N. W. A., Maharrani, R. H., Tripustikasari, E., & Ikhtiangung, Ganjar Ndaru. (2020). Optimation Economic Order Quantity Method for A Support System Reorder Point Stock. *International Journal of Electrical and Computer Engineering (IJECE)*, 10(5), 4992–5000.
- Wei, H., & Zeng, Q. (2021). Research on sales Forecast based on XGBoost-LSTM algorithm Model. *Journal of Physics: Conference Series*, 1754(1), 191–196. <https://doi.org/10.1088/1742-6596/1754/1/012191>
- Wiranda, L., & Sadikin, M. (2019). Penerapan Long Short Term Memory Pada Data Time Series Untuk Memprediksi Penjualan Produk Pt. Metiska Farma. *Jurnal Nasional Pendidikan Teknik Informatika*, 8(3), 184–196.
- Yudhana, A., Umar, Ru., & Saputra, S. (2022). Fish Freshness Identification Using Machine Learning: Performance Comparison of k-NN and Naïve Bayes Classifier. *Journal of Computing Science and Engineering*, 16(3), 153–164.
- Zhang, L., Bian, W., Qu, W., Tuo, L., & Wang, Y. (2021). Time series forecast of sales volume based on XGBoost. *Journal of Physics: Conference Series*, 1873(1), 67–73. <https://doi.org/10.1088/1742-6596/1873/1/012067>





Universitas Islam Negeri
YARIF HIDAYATULLAH JAKARTA

LAMPIRAN

1. Surat Pembimbing Skripsi



**KEMENTERIAN AGAMA
UIN SYARIF HIDAYATULLAH JAKARTA
FAKULTAS SAINS DAN TEKNOLOGI**

Jl. Ir. H. Juanda No. 95 Ciputat 15412 Indonesia
Telp. (62-21) 7493606, 7493547 Fax. (62-21) 7493315

Website : fst.uinjkt.ac.id
Email : fst@uinjkt.ac.id

Nomor : B - 1669E/F9/ KM.01 /06/2024

Jakarta, 03 Juni 2024

Lampiran : -

Perihal : Pembimbing Skripsi

Kepada Yth.

1. Meinarini Catur Utami M.T.

2. Elvi Fetrina M.IT.

Assalamualaikum, Wr Wb

Dengan ini diharapkan kesediaan Saudara untuk menjadi pembimbing I/II/ (Materi/Teknis)* penulisan skripsi mahasiswa:

Nama : MIM HANIFAH PERMANA

NIM : 11200930000048

Program Studi : Sistem Informasi

Judul Skripsi : Peramalan Penjualan Fast Food Dengan Algoritma XGBoost Menggunakan Python

Judul tersebut telah disetujui oleh Program Studi bersangkutan pada tanggal dengan outline, abstraksi dan daftar pustaka terlampir. Bimbingan skripsi ini diharapkan selesai dalam waktu 6 (enam) bulan setelah ditandatanganinya surat penunjukan pembimbing skripsi

Apabila terjadi perubahan terkait dengan skripsi tersebut selama proses pembimbingan, harap segera melaporkan kepada Program Studi bersangkutan.

Demikian atas kesediaan Saudara, kami ucapkan terima kasih.

Wassalamu'alaikum Wr.Wb



Jakarta, 03 Juni 2024

a.n Dekan
Wakil Dekan Bid. Akademik



Dr. Hg Ode Sumarlin, M.Si.
NIDN 197509182008011007/b-

Cek Keaslian Surat di <https://e-letter.fst.uinjkt.ac.id/scan>

2. Data Penjualan Harian D'besto GDC

Date	01/ 23	02/ 23	03/ 23	04/ 23	05/ 23	06/ 23	07/ 23	08/ 23	09/ 23	10/ 23	11/ 23	12/ 23	01/ 24	02/ 24	03/ 24
1	583	444	440	549	539	467	476	405	446	463	391	397	526	446	410
2	539	406	416	475	496	451	499	404	516	374	371	461	496	378	471
3	433	406	432	467	434	420	393	423	560	366	449	450	397	374	383
4	457	424	454	427	509	561	426	475	339	387	438	447	444	442	299
5	369	444	449	399	485	427	437	488	407	411	562	414	469	383	393
6	487	398	375	431	587	406	410	411	420	399	378	434	367	318	399
7	369	340	377	492	510	442	509	353	362	454	418	382	537	393	380
8	513	346	361	539	430	428	433	425	491	530	425	454	445	548	432
9	418	324	351	523	423	441	488	407	454	415	412	474	421	422	406
10	395	373	448	449	405	529	448	408	489	441	420	606	431	437	499
11	379	401	408	554	576	483	434	495	390	363	396	442	384	364	598
12	426	410	419	564	443	449	394	520	373	272	389	421	354	354	599
13	403	390	453	521	454	443	399	556	393	421	462	426	449	469	556
14	448	397	348	549	529	391	438	412	446	515	430	374	441	520	417
15	528	388	389	562	383	408	498	472	415	622	395	440	427	530	364
16	447	374	381	483	381	434	576	405	428	420	419	405	408	376	504
17	338	330	464	624	407	393	454	522	523	401	419	624	289	406	401
18	402	582	506	589	620	543	375	389	385	434	432	443	436	554	443
19	380	427	425	610	409	452	405	417	403	444	465	418	462	437	444
20	454	391	390	650	434	419	397	405	394	460	438	390	554	447	401
21	516	511	451	484	461	489	452	436	426	421	444	400	449	513	433
22	463	366	569		433	607	402	430	440	503	448	444	452	462	379
23	438	443	425		535	543	391	431	402	383	383	494	355	407	361
24	364	400	393	463	416	494	380	419	509	407	437	434	362	489	378
25	375	513	290	462	392	546	428	432	414	383	396	533	337	522	347
26	397	588	387	549	493	452	411	503	396	441	573	543	507	443	325
27	505	481	406	587	435	494	453	461	413	416	389	379	499	438	454
28	421	417	404	483	602	427	507	405	446	445	414	406	481	420	316
29	495		345	438	416	577	476	443	385	470	389	377	341	341	442
30	376		391	452	448	660	527	441	448	392	392	481	335		350
31	374		485		438		388	436		420		619	386		464

3. Data Penjualan Harian D'besto Tapos

Date	01/ 23	02/ 23	03/ 23	04/ 23	05/ 23	06/ 23	07/ 23	08/ 23	09/ 23	10/ 23	11/ 23	12/ 23	01/ 24	02/ 24	03/ 24
1	488	192	287	371	475	374	310	325	366	453	309	450	405	305	305
2	378	209	198	462	391	294	381	324	436	294	358	384	385	267	350
3	343	308	276	234	330	305	385	343	480	286	297	449	292	269	388
4	292	327	402	291	341	364	265	395	259	307	362	345	323	391	232
5	294	350	378	280	308	238	300	408	327	331	522	264	346	260	314
6	291	247	256	240	324	236	332	401	340	389	330	261	270	221	276
7	322	237	253	382	362	281	360	273	282	444	276	282	402	258	255
8	375	246	214	406	330	281	360	345	411	520	268	343	310	413	315
9	248	198	338	444	285	309	435	327	444	335	320	374	294	295	303
10	246	300	304	294	239	342	391	398	479	361	360	400	300	306	366
11	197	351	357	307	274	365	348	415	310	283	417	444	229	359	363
12	262	365	454	319	320	306	267	440	293	219	469	339	187	187	329
13	286	218	230	243	362	313	344	446	313	411	317	354	370	300	429
14	341	232	249	272	384	249	356	332	366	435	336	302	388	397	286
15	357	257	273	341	227	300	457	462	335	542	255	364	302	405	269
16	214	236	260	422	310	330	463	325	418	340	254	387	291	259	387
17	193	265	340	221	240	333	259	442	513	321	422	332	209	303	368
18	240	254	389	307	286	337	357	309	305	354	388	320	303	321	310
19	249	276	391	349	252	280	277	407	323	364	453	374	297	302	309
20	222	288	307	357	239	281	329	395	314	380	307	356	319	312	280
21	322	227	341	371	304	279	300	356	346	411	315	354	332	286	322
22	312	220	327		330	288	287	350	360	423	315	445	321	331	274
23	312	238	251		264	333	381	321	392	303	337	404	260	312	240
24	242	308	222	240	257	445	278	339	429	327	424	414	245	372	327
25	215	302	251	252	246	360	267	422	334	303	292	332	234	319	236
26	312	329	356	295	305	408	289	423	316	361	441	309	304	310	220
27	231	413	247	277	332	431	358	451	333	406	365	328	364	373	323
28	256	268	298	291	354	311	354	325	366	435	336	353	340	299	221
29	306		248	408	288	396	378	363	305	460	263	374	230	230	325
30	232		323	418	290	517	427	361	438	312	316	409	230		347
31	201		401		281		279	356		340		430	265		344

4. Kode Visualisasi Data

```
import pandas as pd, numpy as np, matplotlib as mp, matplotlib.pyplot as plt
import seaborn as sns, xgboost as xgb
from xgboost import plot_importance, plot_tree
from sklearn.metrics import mean_squared_error, mean_absolute_percentage_error
plt.style.use('fivethirtyeight')
from google.colab import drive
drive.mount('/content/gdrive')
df = pd.read_excel('/content/gdrive/MyDrive/mimdataset-skripsi/Dbesto_Sales.xlsx',
                  sheet_name='all')
```

```
sales = df.columns[2:]
for col in sales:
    print(df[col].agg(['mean', 'median']))
    plt.figure(figsize=(15,4))
    plt.subplot(1,2,1)
    sns.histplot(df[col], kde=True)
    plt.title(f'Distribution of {col}'); plt.show()
```

```
for col in sales:
    df_holiday_1 = df[df['Holiday'] == 1][col]
    df_holiday_0 = df[df['Holiday'] == 0][col]
    mean_holiday_1 = df_holiday_1.mean().round(0)
    mean_holiday_0 = df_holiday_0.mean().round(0)
    print(f"Mean {col} on holidays: {mean_holiday_1}")
    print(f"Mean {col} on non-holidays: {mean_holiday_0}")
    plt.figure(figsize=(10, 6))
    sns.histplot(df_holiday_1, label="Holiday", kde=True, stat="density", alpha=0.5)
    sns.histplot(df_holiday_0, label="Non-holiday", kde=True, stat="density", alpha=0.5)
    plt.xlabel(col)
    plt.ylabel("Density")
    plt.title(f"Comparison of {col} on Holidays and Non-holidays")
    plt.legend()
    plt.show()
```

```
days = ['Monday', 'Tuesday', 'Wednesday', 'Thursday', 'Friday', 'Saturday', 'Sunday']
sales = ['GDC_sales', 'Tapos_sales']
```

```
for col in sales:
    df_sales_by_day = df_holiday_0.groupby('Dayofweek')[col].mean().reset_index()
    df_sales_by_day.rename(columns={'Dayofweek': 'Day'}, inplace=True)
    plt.figure(figsize=(10, 6))
    sns.lineplot(data=df_sales_by_day, x='Day', y=col, markers=True, dashes=False)
    plt.xticks(ticks=range(len(days)), labels=days)
    plt.xticks(rotation=45)
    plt.title(f'Average Sales by Day of the Week ({col.split("_")[0]})')
    plt.xlabel('Day')
    plt.ylabel('Average Sales')
    plt.show()
```

5. Tabel Z-score untuk *Service Level*

Service Level Required (%)	Safety Stock Coverage Factor Z-Score	Incremental Service Level (%)
50%	0.000	50.00%
70%	0.524	20.00%
75%	0.674	5.00%
80%	0.842	5.00%
81%	0.878	1.00%
82%	0.915	1.00%
83%	0.954	1.00%
84%	0.994	1.00%
85%	1.036	1.00%
86%	1.080	1.00%
87%	1.126	1.00%
88%	1.175	1.00%
89%	1.227	1.00%
90%	1.282	1.00%
91%	1.341	1.00%
92%	1.405	1.00%
93%	1.476	1.00%
94%	1.555	1.00%
95%	1.645	1.00%
96%	1.751	1.00%
97%	1.881	1.00%
98%	2.054	1.00%
99%	2.326	1.00%
99.5%	2.576	0.50%
99.90%	3.090	0.40%